

Rapport de Stage

Méthode de cartographie de zones humides potentielles en Haute-Garonne
par *random forest* à partir d'images satellitaires : adaptation et
contributions à la méthode REAUZOH

Master 2 IGAST
Information Géographique : Analyse Spatiale et Télédétection

Niels SAURA
Soutenance le 22 septembre 2026

Encadrants :
Téodolina LOPEZ (OSECC - Cerema Occitanie)
Nicolas OLIVEIRA-SANTOS (OSECC - Cerema Occitanie)

Année 2025–2026

Résumé

L’inventoriage des zones humides sur le terrain est un processus long et coûteux. Il en résulte que ces inventaires sont inégalement disponibles selon les régions et souvent datés. Il existe également une Cartographie Nationale des Zones Humides (CNZH), réalisée par l’institut PatriNat, issue d’une classification par random forest à partir de variables hydrologiques, topographiques et géologiques. Cependant, le choix de ces variables ne permet pas de suivi inter-annuel, ni de détection des zones humides artificialisées ou drainées.

La méthode REAUZOH, développée par le Cerema, pallie ces limites par l’intégration d’images satellites optiques (Sentinel-2) et SAR (Sentinel-1). Cette méthode nécessite toutefois un jeu de vérité terrain réalisé *in situ* par des experts, ce qui en limite la reproductibilité. Elle a également été mise au point sur une communauté de commune de petite superficie.

Nous avons adapté cette méthode au département de la Haute-Garonne et à l’absence de jeu de vérité terrain *ad hoc*. Nos contributions principales à cette méthode sont : (i) modification de la méthode de constitution du jeu de données, en utilisant un inventaire publique et en constituant un jeu de vérité terrain négatif à partir de la CNZH ; (ii) affinage du jeu de données positif pour tenir compte de la variabilité saisonnière des zones humides ; (iii) implémentation d’une étape d’extraction des caractéristiques des variables d’entrée par Analyse en Composante Principale ; (iv) amélioration de l’optimisation des hyperparamètres du random forest par l’algorithme Tree-Structured Parzen Estimator. Notre méthode montre de bons résultats sur le jeu de données global (f1-score moyen de 84%, ROC-AUC de 0.93) mais sur-évalue la présence de zones humides dans les zones boisées (rappel de 64% des non zones humides de fort NDVI).

Nous présentons également une étude de l’apport marginal à cette méthode des produits de température de surface (TS) Landsat et ECOSTRESS et des images du satellite NISAR (images SAR de bande L en polarisation horizontale). Nous avons extrait des médianes saisonnières des TS des satellites Landsat et une image d’amplitude thermique journalière des TS du capteur ECOSTRESS. Nous avons utilisé les images NISAR de rétrodiffusion et de cohérence de phase entre deux acquisitions. Notre étude ne montre pas d’amélioration significative de la classification en ajoutant les images de TS (f1-score moyen de $81.4 \pm 0.1\%$ contre $81.4 \pm 0.2\%$ pour la méthode témoin) et une légère amélioration en ajoutant les images NISAR (f1-score moyen de $79.7 \pm 0.2\%$ contre $79.3 \pm 0.2\%$ pour la méthode témoin).

Table des matières

Introduction	4
1 Données de référence et variables prédictives	7
1.1 Choix de la zone d'étude et vérité terrain	7
1.1.1 Limites et biais de l'inventaire pour notre stage	7
1.2 Variables Prédictives	8
1.2.1 Choix de l'année et de la grille commune	8
1.2.2 Images Optiques	8
1.2.3 Températures de Surface	9
1.2.4 Images SAR	12
1.2.5 Données Topographiques	13
1.2.6 Information Temporelle	14
2 Étude de la Discriminabilité par random forest	14
2.1 Reproduction de la méthode REAUZOH	14
2.1.1 Constitution du jeu de données	14
2.1.2 Chaîne de traitement de la reproduction de la méthode REAUZOH	15
2.1.3 Validation et Inférence du modèle	18
2.2 Méthode Modifiée	19
2.2.1 Constitution du jeu de données	19
2.2.2 Chaîne de production de la cartographie des zones humides potentielles	24
2.2.3 Validation et Inférences	26
3 Étude de l'apport de nouvelles données satellitaires à la détection de zones humides par <i>random forest</i>	30
3.1 Étude de l'apport de la température de surface Landsat	30
3.2 Étude de l'apport des images NISAR	31
4 Synthèse des Résultats, Limites et Perspectives	32
4.1 Apports	32
4.2 Limites	35
4.3 Perspectives	36
Conclusion	37
Bibliographie	38
Annexe	41
A Images du nombre d'acquisitions Landsat par mois de l'année 2019	41
B Fonctionnement d'un <i>random forest</i>	43
C Théorie de l'Analyse en Composantes Principales	44
D Principe du <i>Tree-Structured Parzen Estimator</i>	45

Introduction

La catégorie de zone humide vient de l'aménagement du territoire et de la conservation de l'environnement et s'est imposée à partir de la convention internationale de Ramsar de 1971. Elle subsume une grande variété de milieux, liés à des histoires, des cultures et des pratiques très différentes. Il s'agit de milieux qui peuvent ou non être exploités par les humains et qui sont inondés ou gorgés d'eau douce, saumâtre ou salée, tout ou partie de l'année. En France, cela peut regrouper des tourbières, des marais, des salins, des landes, des prairies, des forêts ou encore des mangroves. Le terme de zone humide fait l'objet d'une définition légale à l'échelle nationale, qui en fixe les critères de détermination¹, soit selon des critères pédologiques permettant de caractériser l'hydromorphisme du sol, soit selon la présence de plantes hygrophiles.

La naissance de cette catégorie est due à l'identification de ce type de milieux comme particulièrement critiques pour la biodiversité car un grand nombre d'espèces d'oiseaux migratrices en dépendent pour leur survie. Les zones humides jouent également un rôle important pour le ralentissement du cycle de l'eau, la filtration de l'eau et la conservation des sols, qui sont aujourd'hui des enjeux majeurs. Elles agissent comme des tampons de grande ampleur, permettant de contenir les inondations et de retarder les sécheresses et ont une capacité de stockage du carbone plus importante que les forêts.

Cependant, ces milieux sont également considérés parmi les plus menacés et dégradés au monde. L'Office Français de la Biodiversité rappelle ainsi que leur disparition dans le monde est 3 fois plus rapide que celle des forêts (OFFICE FRANÇAIS DE LA BIODIVERSITÉ, 2026) et que leur superficie est estimée avoir diminué de 86% depuis le XVIII^e siècle. En France, elle aurait diminué de 50% pendant les "Trente Glorieuses", entre 1960 et 1990. Ces disparitions sont en bonne partie dues au pompage excessif, notamment pour des cultures fourragères demandeuses en eau, à l'expansion d'une agriculture industrielle et à l'urbanisation. À ces disparitions s'ajoutent les dégradations, notamment les pollutions de l'eau, dont l'eutrophisation². La directive européenne Habitats-Faune-Flore estime ainsi à 6% la proportion des habitats humides en bon état de conservation en 2018.

Pour différents acteurs de l'aménagement du territoire ou de l'environnement dans le monde entier, disposer de connaissances détaillées sur ces milieux critiques est donc d'une grande importance. Il existe justement de très nombreux travaux universitaires depuis les années 1970, qui proposent des méthodes pour inventorier les zones humides. MAHDAVI et al. (2018) et YUAN et al. (2025) notent que la télédétection aérienne et satellitaire a été mobilisée dès les années 70 pour inventorier les zones humides, en raison des gains de temps et d'argent significatifs que cette méthode permet par rapport aux inventaires de terrain. On peut ajouter que les inventaires de terrain eux-mêmes, commencent souvent par une phase de sélection de zones humides potentielles mobilisant de la télédétection. Réciproquement, la majorité des méthodes d'inventaire par télédétection utilisent des données de terrain pour leur validation et pour leur entraînement, dans le cas des méthodes automatiques. YUAN et al. (2025) identifient deux tendances dans les évolutions des méthodes d'inventaire de zones humides depuis cette décennie séminale. Premièrement, à mesure que de plus en plus de données de télédétection ou de SIG sont devenues accessibles, ces méthodes d'inventaire sont devenues davantage multi-modales, alors qu'elles tendaient initialement à ne reposer que sur un seul type d'images. Deuxièmement, pour tirer parti de ces très grands volumes de données, de plus en plus de méthodes d'inventaire, proposées dans des articles de recherche, mobilisent des méthodes d'apprentissage automatique.

MAHDAVI et al. (2018) rappellent que les premiers inventaires par télédétection se faisaient par analyse d'images aériennes RGB³. Les satellites Landsat de la NASA, équipés de capteurs optiques multispectraux, ont rapidement fait ressortir la pertinence des images optiques en dehors du spectre visible. Ils

1. Arrêté du 24 Juin 2008 modifié par l'arrêté du 1er Octobre 2009 précisant les critères de définition et de délimitation des zones humides en application des articles L. 214-7-1 et R. 211-108 du code de l'environnement.

2. Enrichissement de l'eau en nitrate du fait des engrais agricoles et de l'épandage du fumier. Cela entraîne une prolifération d'algues, qui consomment toute l'oxygène et asphyxient le milieu.

3. *Red Green Blue*. Images correspondant à la vision humaine.

compilent différentes études ayant notamment montré la pertinence des bandes dites *Red Edge*⁴ et proche infrarouge⁵ pour distinguer différents types de zones humides entre eux. L'utilisation d'images issues de capteur SAR⁶, avec notamment les missions Radarsat et ALOS PALSAR, s'est également imposée dans la première décennie des années 2000, comme incontournable pour ce type d'inventaires. Les images SAR ont une importante fréquence temporelle⁷, et ne sont pas affectées par les nuages. Elles fournissent également des informations fines sur l'intensité et la dynamique temporelle de la végétation et de l'humidité. Certaines polarisations et bandes radar⁸ sont également capables d'atteindre le sol de zones de forêts. Ces caractéristiques sont des atouts indéniables pour inventorier les zones humides. En règle générale, les images satellitaires permettent de disposer de séries temporelles beaucoup plus denses que les images aériennes. De nombreux autres types de données, comme des données topographiques, hydrologiques, géologiques, floristiques, climatiques et d'occupation du sol, ont également pu être mobilisés dans différentes études.

À mesure que le nombre de données augmente, en tirer parti par inspection visuelle devient plus difficile. Dans les articles de recherche, YUAN et al. (2025) montrent ainsi que l'inspection visuelle s'est vue de plus en plus souvent remplacée par des méthodes au moins en partie automatisées. Différentes méthodes ont ainsi mobilisé de la segmentation d'objets à différentes échelles, par proximité radiométrique, puis une analyse des objets segmentés [GRENIER et al., 2008]. D'autres méthodes ont utilisé des arbres de décision construits à partir de seuils déterminés par des experts. Des méthodes de *machine learning* comme le groupement par *k-means* [JING et al., 2020], les Machines à Vecteur de Support⁹ [LIN et al., 2013] ou encore le groupement par vraisemblance maximale¹⁰ [LANE et al., 2014], parfois couplées à des réanalyses par des experts, ont également été utilisées. Toutefois YUAN et al. (2025) remarquent que ces méthodes nécessitent des présuppositions sur la distribution statistique des classes : le maximum de vraisemblance pré-suppose des distributions de classe normales, le groupement par *k-means* suppose des distributions sphériques et le SVM, en plus d'avoir une complexité prohibitive sur des gros jeux d'entraînement, nécessite une paramétrisation experte de la forme de la frontière à déterminer pour séparer les classes. Par contraste, le *random forest* ne nécessite aucune pré-supposition sur la forme des distributions de classe tout en identifiant des frontières inter-classe non linéaires. C'est également un type de modèle capable d'ingérer un grand nombre de variables de toute nature en entrée et de gérer de grands jeux d'entraînement. Cependant, ce modèle nécessite toujours une extraction des caractéristiques pertinentes à la main : un expert doit déterminer les pré-traitements d'images et les informations à fournir au modèle, à partir des données brutes. L'apprentissage profond répond à cette limite, puisque l'extraction de caractéristiques est directement incluse dans l'architecture de ces modèles. Un nombre croissant d'études mobilisent ainsi des architectures d'apprentissage profond. YUAN et al. (2025) et EFFAH et al. (2025) identifient notamment la popularité pour l'inventoriage des zones humides des réseaux convolutifs [POULIOT et al., 2019], des GAN¹¹ [HE et al., 2019] et des *Transformers* [JAMALI et MAHDIANPARI, 2022].

Il est important de noter que l'apparition de nouvelles méthodes ne semble pas se faire en en supplantant d'autres. YUAN et al. (2025) nous fournissent un graphique l'illustrant, reproduit en figure 1. On y lit une augmentation globale du nombre d'articles consacrés au sujet, sans disparition réelle d'une méthode, exceptée l'interprétation visuelle. De plus, ce graphique et les tendances que nous avons rapportées se concentrent sur les articles de recherche, qui ont vocation à explorer de nouvelles méthodes et données. Dans la pratique des cabinets d'étude et agences, chargés d'inventaire, des méthodes efficaces bien que non innovantes, dont l'inspection visuelle d'images aériennes, restent vraisemblablement assez utilisées. C'est notamment le cas pour l'inventaire dont nous nous servons comme vérité terrain dans ce rapport.

Malgré la complexité croissante de la modélisation des zones humides, MAHDAVI et al. (2018) et YUAN et al. (2025) notent des limites persistantes : des performances encore assez mauvaises pour la distinction des différents sous-types de zones humides et une modélisation souvent statique temporellement, qui ne prend pas en compte la variabilité saisonnière et l'évolution inter-annuelle des zones humides. GRIMSON et al. (2026) et GUIDUGLI-COOK et al. (2017) pointent également une focalisation des méthodes d'inventaire proposées sur les zones humides inondées le long de cours d'eau, plus simples à détecter, ainsi qu'une sous-représentation dans les inventaires produits *in situ* ou par télédétection, des zones humides éloignées

4. Bandes qui correspondent à des longueurs d'onde d'environ 700nm à 800nm.

5. D'environ 800nm à 900nm de longueur d'onde.

6. *Synthetic Aperture Radar*, radar à synthèse d'ouverture en français. Technologie d'imagerie radar satellitaire permettant d'améliorer la résolution en azimuth en simulant une ouverture plus grande que la section réelle de l'antenne, par synthèse de différentes acquisitions.

7. Notamment du fait des acquisitions en orbite ascendant et descendant.

8. Notamment la bande L (≈ 24 cm) émise en polarisation horizontale.

9. SVM selon leur acronyme anglophone d'usage courant.

10. Méthode souvent désignée de son nom anglais *maximum likelihood*.

11. *Generative Adversarial Networks*




FIGURE 1 – "Évolution des données, méthodes et échelles des publications typiques au cours des années" [YUAN et al., 2025]

de cours d'eau et sous une végétation dense.

Dans le contexte français, les inventaires *in situ* de zones humides sont inégalement disponibles. De plus, quand ils sont disponibles, ils sont souvent datés, ce qui est dommageable pour des milieux particulièrement menacés. Il existe une cartographie produite pour la France entière par l'institut PatriNat et appelée Cartographie Nationale des Zones Humides (CNZH) [RAPINEL et al., 2023]. Cette cartographie a été produite en compilant l'ensemble des bases de données publiques d'inventaires pédologiques et/ou floristiques et en appliquant à ces données d'inventaire les critères réglementaires français pour caractériser les zones humides. Ce jeu de vérité terrain est ensuite utilisé pour entraîner un *random forest*, à partir de variables uniquement hydrologiques, topographiques et géologiques. Cette cartographie identifie très bien les zones qui sont géomorphologiquement propices à la formation de zones humides. Elle a ainsi un très bon rappel : les zones humides réelles ont de grandes chances d'être bien classées par cette cartographie. Cependant, du fait des variables prédictives qu'elle emploie, cette méthode n'est pas en mesure de distinguer une zone humide avérée, d'une zone qui l'a peut-être été mais qui est désormais drainée par exemple. Ceci constitue une limite importante, que l'ajout d'images satellitaires dans la modélisation, permettrait de pallier. De plus, la focalisation uniquement hydrogéomorphologique conduit cette cartographie à reproduire les biais des inventaires, soulevés précédemment : sur-représentation des zones humides proches de cours d'eau et sous représentation des zones humides sous couvert forestier. Cette cartographie est ainsi peu discriminante dans les grandes vallées, comme celle de la Garonne. En outre, le jeu de vérité terrain constitué à l'échelle nationale, bien que d'une ampleur inédite en France et le fruit d'un effort de compilation d'une grande complexité, n'est pas homogènement réparti sur tout le territoire. Les auteurs reconnaissent ainsi des performances variables selon les régions. Enfin, la méthode de production de cette cartographie ne permet pas une actualisation et donc un suivi de la variabilité saisonnière et de l'évolution inter-annuelle des zones humides, là encore à cause de la nature de ses variables prédictives.

Le Cerema et la CABBALR¹² ont ainsi souhaité développer une méthode de cartographie de zones humides potentielles cherchant à surmonter ces limites, dans le cadre d'un appel à partenaires GEMAPI. Cela a abouti à la méthode dite REAUZOH¹³ [OLIVEIRA-SANTOS et al., 2025]. Le stage, dont ce document constitue le rapport, vise à prolonger cet effort de production méthodologique. Ce stage a été accueilli par le groupe Observation Satellitaire et Changement Climatique (OSECC) de la Direction Territoriale Occitanie du Cerema, à Toulouse. Dans la continuité de la méthode REAUZOH, les objectifs de notre stage sont :

1. établir une méthode de cartographie à échelle régionale et facilement reproductible dans différents contextes, sans nécessité de connaissances expertes en zones humides, pour pallier les zones blanches des cartographies de petite échelle ;
2. établir une méthode tenant compte, dans sa modélisation, de la variabilité saisonnière des zones humides ;
3. établir une méthode reproductible d'années en années, pour permettre le suivi de ces milieux dégradés ;
4. établir une méthode représentant mieux les zones humides sous végétation dense et éloignées de cours d'eau.

12. Communauté d'agglomération de Béthune Bruay Artois Lys Romane

13. REcensement, cArtographie et sUivi de l'évolution des Zones pOtentiellement Humides

Nous présenterons dans un premier temps notre zone d'étude, nos données de référence, nos variables prédictives et les pré-traitements réalisés sur ces variables (chapitre 1). Nous montrerons ensuite les limites que nous avons constatées en réimplémentant, de manière naïve, la méthode développée en Normandie sur notre nouvelle zone d'étude et avec de nouvelles données d'entraînement (section 2.1). Nous détaillerons ensuite les modifications que nous avons apportées à cette méthode pour en améliorer les performances, au regard des quatre objectifs cités (2.2). Enfin, nous présenterons une estimation de l'apport de nouvelles sources de données, à savoir les températures de surface issues des satellites Landsat et ECOSTRESS, et les images de bande L, issues du satellite NISAR (3).

Chapitre 1

Données de référence et variables prédictives

1.1 Choix de la zone d'étude et vérité terrain

Le stage à l'origine de ce rapport est financé par la région Occitanie, ce qui impliquait que sa zone d'étude se trouvât dans cette région. Les zones humides côtières et continentales présentent des phénotypes assez différents. Nous avons fait le choix de nous concentrer sur les zones humides continentales. Enfin, l'existence d'un inventaire détaillé et de grande ampleur pour le département de la Haute-Garonne, ainsi que la localisation du stage dans ce département, nous a semblé justifier le choix de ce département comme zone d'étude.

Les moyens humains et financiers du stage rendaient nécessaires l'utilisation de données de vérité terrain pré-constituées et accessibles. L'inventaire réalisé par le cabinet d'étude Ecotone pour le conseil départemental de la Haute-Garonne de 2013 à 2016, nous a servi de référence pour les zones humides avérées ([ECOTONE, 2013] et [ECOTONE, 2016]). Cet inventaire a été réalisé selon le critère de présence de plantes hygrophiles, en application de l'arrêté du 24 juin 2008 modifié par l'arrêté du 1er octobre 2009, déjà cité.

Les écologues ont commencé par déterminer des zones humides potentielles à confirmer par inventaire. La détermination de ces zones a mobilisé des images hydromorphologiques, proches de celles utilisées pour la production de la CNZH et des images optiques dans le domaine visible, en l'occurrence des orthophotographies à 20 cm du département. Ces images ont été analysées visuellement. En outre, les zones de pré-localisation ont été enrichies des informations recueillies auprès des associations et institutions écologistes locales et d'un inventaire sur une région restreinte déjà réalisé.

1.1.1 Limites et biais de l'inventaire pour notre stage

Une première limite est que cet inventaire ne nous fournit qu'un jeu de vérité terrain positif. Disposer de points d'inventaire négatifs, phénologiquement proches de véritables zones humides, est d'une grande utilité pour l'entraînement d'un modèle automatique.

La sur-représentation des données hydromorphologiques, pour la détermination des zones humides potentielles par inspection visuelle durant la phase de pré-inventaire, laisse également supposer un éventuel biais de sous représentation de zones humides éloignées de cours d'eau.

Enfin, cet inventaire avait pour objectif principal la protection des zones humides en Haute-Garonne. Ainsi, les auteurs de l'inventaire expliquent avoir concentré leurs efforts dans les zones les plus menacées. La carte de la figure 1.1, montre ainsi notamment un effort plus important dans les bassins versants du Sor et du Laudot (Est du département), dont les ripisylves sont identifiées comme particulièrement menacées par l'agriculture. Cela implique possiblement une sous-estimation des zones humides en zones

Catégorie	Indice	Acronyme	Formule	Bandes Sentinel-2	Référence
Végétation	Normalized Difference Vegetation Index	NDVI	$\frac{NIR - R}{NIR + R}$	$\frac{B8 - B4}{B8 + B4}$	Rouse et al., 1974
	Enhanced Vegetation Index	EVI	$\frac{2.5 * (NIR - R)}{(NIR + 6 * R - 7.5 * B + 1)}$	$\frac{2.5 * (B8 - B4)}{(B8 + 6 * B4 - 7.5 * B2 + 1)}$	Liu and Huete, 1995
Eau	Normalized Difference Water Index	NDWI	$\frac{NIR - SWIR2}{NIR + SWIR2}$	$\frac{B8 - B12}{B8 + B12}$	Gao, 1996
	Normalized Difference Water Index 2	NDWI2	$\frac{G - NIR}{G + NIR}$	$\frac{B3 - B8}{B3 + B8}$	McFeeters, 1996
	Modified Normalized Difference Water Index	MNDWI	$\frac{G - SWIR2}{G + SWIR2}$	$\frac{B3 - B12}{B3 + B12}$	Xu, 2006
	Normalized Difference Moisture Index	NDMI	$\frac{NIR - SWIR1}{NIR + SWIR1}$	$\frac{B8 - B11}{B8 + B11}$	Gao, 1996
	Moisture Stress Index	MSI	$\frac{SWIR1}{NIR}$	$\frac{B11}{B8}$	Hunt and Rock, 1989
Sol	Brightness Index	BI	$\sqrt{\frac{R^2 + G^2}{2}}$	$\sqrt{\frac{B4^2 + B3^2}{2}}$	Escadafal et al., 1989
	Brightness Index 2	BI2	$\sqrt{\frac{R^2 + G^2 + NIR^2}{3}}$	$\sqrt{\frac{B4^2 + B3^2 + B8^2}{3}}$	Escadafal et al., 1989
	Bare Soil Index	BSI	$\frac{(R + SWIR1) - (NIR + B)}{(R + SWIR1) + (NIR + B)}$	$\frac{(B11 + B4) - (B8 + B2)}{(B11 + B4) + (B8 + B2)}$	Chen et al., 2004

FIGURE 1.2 – Formules des indices optiques calculés avec les bandes de Sentinel-2 correspondantes. source : [OLIVEIRA-SANTOS et al., 2025]

UTM31N en utilisant la librairie python odc-geo, qui permet de paralléliser la reprojection sur plusieurs CPU et ainsi de tirer parti des serveurs de calcul dont nous disposons. Seulement deux images sur les 12 présentent quelques régions de nuage.

Dans la continuité de la méthode REAUZOH [OLIVEIRA-SANTOS et al., 2025], nous avons ensuite calculé un nombre important d'indices optiques, résumés dans la figure 1.2.

1.2.3 Températures de Surface

Landsat

Les satellites Landsat de la NASA sont une source importante de données de température de surface (TS) accessibles publiquement. Ces données sont issues de la 10^{me} bande du capteur de ces satellites, qui capte la lumière de 10,6 μm à 11,2 μm de longueur d'onde, ce qui est dans la plage théorique d'émission de la Terre. L'intensité de cette bande permet donc d'obtenir la température de surface d'un corps noir T_{cn} . Couplée avec une estimation de l'émissivité de la surface $\epsilon \in [0, 1]$, on peut ainsi obtenir une estimation de la température de surface réelle T_{cg} , telle que $T_{cn} = \epsilon T_{cg}$.

Les capteurs des satellites ASTER et le capteur ECOSTRESS, possèdent plusieurs bandes dans l'infrarouge thermique, ce qui leur permet d'estimer l'émissivité de la surface observée sans information extérieure. Cela n'est pas le cas pour les capteurs des satellites Landsat, qui utilisent ainsi un produit d'émissivité dérivé des images ASTER. Cela rend les estimations de températures de surface moins précises que celles de ces autres satellites.

Les produits TS des satellites Landsat sont disponibles à une meilleure fréquence que les images ASTER. Leur résolution spatiale est de 100 m par 100 m, comme ASTER mais inférieure à ECOSTRESS (résolution de 70 m par 70 m). Les TS Landsat se démarquent également des TS ECOSTRESS par le fait que les satellites Landsat ont des orbites héliosynchrones, ce qui signifie que l'heure solaire locale est toujours la même à leur nadir. Cette propriété est particulièrement appréciable pour estimer la température de surface, qui varie fortement au cours de la journée. Cela rend ces images d'une utilisation plus simple mais potentiellement moins riche, que les images ECOSTRESS, dont les heures d'acquisition sont variables.




FIGURE 1.3 – Histogramme des heures d’acquisition des différents Satellites Landsat sur la Haute-Garonne entre 2019 et 2022

Il est cependant important de noter que les produits TS fournis par la NASA sont rééchantillonnés à 30m de résolution spatiale et pré-traités, notamment pour en lisser le gradient. Il n’est, selon nos recherches, pas possible d’obtenir les produits non rééchantillonnés et pré-traités.

Malgré cette plus grande facilité d’utilisation, pour garantir une comparabilité entre les différents points dont on étudiera la température de surface en Haute-Garonne, il faut prendre quelques précautions. Nous souhaitons ainsi nous assurer que les heures d’acquisition soient bien similaires, des différences systématiques de quelques dizaines de minute entre deux zones pouvant biaiser la comparaison de leur température de surface. Nous souhaitons également nous assurer que les dates d’acquisition soient les mêmes. En effet, la température de surface est soumise à des variations très fortes. Si nous avons accepté pour les données Sentinel-1 et Sentinel-2 de comparer des agrégats mensuels de pixels qui n’étaient pas acquis sur les mêmes orbites et donc pas aux mêmes dates, cette approximation devient plus pénalisante pour les images de température de surface et pour quantifier précisément l’apport de ces images.

Heures d’acquisition

Nous avons téléchargé toutes les images Landsat de température de surface couvrant une partie de la Haute-Garonne de 2019 à 2022. Durant cette période, 3 satellites Landsat, numérotés de 7 à 9, ont été en activité. Sur la Haute-Garonne, nous avons des images du satellite Landsat 7 jusqu’en décembre 2021 avec une interruption en 2020. Le satellite Landsat 8 (L8) est actif sur toute la période et le satellite Landsat 9 (L9) fournit ses premières images de la Haute-Garonne à partir de Décembre 2021. Cependant, un défaut sur le capteur de Landsat 7 (L7) entraîne des stries sur ses acquisitions. En plus de ce problème de qualité d’images, le satellite L7 présente des fortes variabilités d’heures d’acquisition sur notre période d’étude. On peut ainsi voir sur la figure 1.3 que les heures d’acquisition forment des raies pour L8 et L9. Chaque raie correspond à une tuile différente. Les images L8 et L9 sont donc assez ponctuelles et comprises dans un intervalle de moins de 10 minutes (de 10h35 du matin à un peu moins de 10h45). En revanche, les images L7 sont étalées sur un intervalle d’une heure, d’environ 9h30 à 10h30. La température de surface peut varier fortement dans cet intervalle et il est donc hasardeux méthodologiquement d’essayer de comparer des TS provenant de ce satellite. Nous avons donc complètement exclu le satellite L7 de notre corpus.

Nombres d’acquisitions et détermination d’une aire géographique méthodologiquement pertinente

La Haute-Garonne est à l’intersection de plusieurs tuiles Landsat. Cependant, ces tuiles ont un certain recouvrement entre elles, ce qui induit une sur-représentation des zones incluses dans le recouvrement. En outre, deux tuiles non couvertes par le même orbite auront structurellement des dates d’acquisition différentes. La température de surface pouvant varier fortement d’un jour à l’autre, nous avons souhaité ne conserver que des zones appartenant aux mêmes tuiles pour notre étude, pour ne pas introduire un biais en fonction de la localisation géographique. Il s’avère que la Haute-Garonne est couverte presque en intégralité par l’intersection de deux tuiles Landsat ⁵. Nous avons donc choisi cette intersection comme

5. Il s’agit de la tuile d’orbite 198 et de ligne 30 et de la ligne d’orbite 199 et de ligne 30.

zone d'étude pour utiliser les données Landsat et n'avons conservé que les images de ces tuiles.

Médianes Saisonnières

La plupart des mois de 2019 ne présentent pas une acquisition complète, comme l'illustrent les images du nombre d'acquisition présentées en annexe A.

Produire un agrégat mensuel est donc inadapté. Nous avons donc ramené chaque acquisition à des groupes de trois mois consécutifs inter-annuels (on groupe ensemble des pixels de même mois bien que d'années différentes). Pour chaque agrégat saisonnier et inter-annuel obtenu, nous avons ensuite choisi de conserver la médiane. Nous avons choisi la médiane, plutôt que la moyenne, le minimum ou le maximum, pour avoir des images qui ne soient pas trop sensibles aux valeurs aberrantes ou extrêmes, qui sont fréquents dans les séries temporelles de TS.

Le fait d'agréger des informations sur quatre années, en une image, entache l'ambition de diachronie de notre méthode. Un tel agrégat ne permet pas de détecter des évolutions d'années en années et peut créer des faux positifs ou négatifs si une zone humide se crée ou disparaît pendant la période choisie. Une autre possibilité aurait été de produire un agrégat annuel, comme la médiane pour toute l'année 2019. Cela aurait permis une meilleure diachronie des prédictions, au prix d'une moins bonne modélisation de la variabilité saisonnière des zones humides.

ECOSTRESS

ECOSTRESS est un capteur multispectral qui inclut 5 bandes dans l'infrarouge thermique (de 8 μm à 12 μm) et qui équipe la station spatiale internationale. La station spatiale internationale n'est pas un satellite héliosynchrone et est également sur une orbite plus basse que ces satellites. Il en résulte que les images d'infrarouge thermique captées par ECOSTRESS ont une meilleure résolution que celles des satellites héliosynchrones et sont également acquises à des heures aléatoires. Les produits de température de surface qui en sont dérivés permettent ainsi de reconstituer des profils thermiques sur toute une journée, donnant des informations sur l'amplitude thermique journalière et non seulement sur la moyenne thermique d'un pixel.

Nous avons récupéré ces images géoréférencées via la plateforme AppEEARS de la NASA⁶. Pour fournir à notre modèle des agrégats temporels, nous ne pouvons pas simplement moyenner les images ECOSTRESS, puisqu'elles sont acquises à des heures différentes et que tous les pixels n'ont pas été acquis aux mêmes moments (à cause des nuages et de la taille de la fauchée). Nous avons donc postulé que le profil thermique journalier d'un pixel est une onde sinusoïdale d'une période de 24 heures. Pour

chaque pixel, on a $X = \begin{bmatrix} h_1 \\ \vdots \\ h_n \end{bmatrix}$ avec h_i l'heure de exacte de la i^{me} acquisition et $Y = \begin{bmatrix} t_1 \\ \vdots \\ t_n \end{bmatrix}$ avec t_i la

température de surface de la i^{me} acquisition. En posant $X_{sin} = \sin(\frac{X}{24} \times 2\pi)$ et $X_{cos} = \cos(\frac{X}{24} \times 2\pi)$, on cherche alors à trouver a, b et c, qui minimise $E((\hat{Y} - Y)^2)$ avec $\hat{Y} = aX_{sin} + bX_{cos} + c$. Le problème devient ainsi un problème de régression linéaire multivarié, qui est soluble analytiquement. On peut donc en trouver les solutions bien plus rapidement qu'avec les algorithmes de minimisation de l'erreur quadratique par descente du gradient ou méthodes analogues. Pour construire X , il faut choisir une durée d'acquisition, que l'on va ramener à un pseudo-profil journalier. Nous avons testé des périodes d'un mois, de trois mois et d'une année. Pour chaque pixel et durée, on obtient trois paramètres qui permettent de caractériser une onde sinusoïdale de profil thermique journalier.

On peut alors produire des moyennes de température, standardisées pour des pixels d'heures d'acquisitions différentes mais aussi des images d'amplitude thermique journalière. Ce second type d'images est intéressant, car l'amplitude thermique est liée à l'inertie thermique des surfaces et n'est pas obtainable à partir de capteurs de satellites héliosynchrones. Or, l'inertie thermique de l'eau est très forte, les pixels de faible amplitude thermique peuvent donc apporter une information pouvant être liée à l'humidité des sols.

Nous avons pu constater des artefacts importants sur les images d'amplitude thermique produites, dus à des défauts dans les images fournies par ECOSTRESS. Nous avons testé différentes techniques de traitement de ces artefacts mais la plus efficace s'est avérée être la moins sophistiquée : filtrer les pixels des images d'origine, avec des températures de surface inférieures à -25°C ou supérieures à 45°C. Nous avons également supprimé les images qui couvraient moins de 7% de la zone d'étude.

6. <https://appeears.earthdatacloud.nasa.gov/>




FIGURE 1.4 – Images d’amplitude de température de surface journalière en degrés Celcius de la Haute-Garonne pour toute l’année 2019 (a) et de janvier à mars (b), dérivées des températures de surface ECOSTRESS

Seule l’image annuelle ne présentait pas de manques de données. C’est donc celle-ci que nous avons fournie à notre modèle pour estimer l’apport de la TS (section 3.1), bien qu’elle soit moins contrastée que les images obtenues sur des plus petits pas de temps, comme le montre la figure 1.4.

1.2.4 Images SAR

Sentinel-1

Nous avons téléchargé les images dites *Ground Range Detected*⁷ (GRD) produites par les satellites Sentinel-1 (S1), de l’année 2019 via *google earth engine*⁸.

Les images radar présentent un bruit multiplicatif appelé chatoiement, qui est causé par les interférences entre les signaux rétrodiffusés avec des phases décalées par les différents réflecteurs de la scène agrégée dans un pixel. Moyenner un pixel spatialement ou temporellement est une très bonne manière d’atténuer ce bruit multiplicatif. Les satellites S1 ont l’avantage d’offrir une revisite temporelle très élevée, de l’ordre de 6 jours. Cette fréquence permet d’utiliser un compromis entre moyennage temporel et spatial, qui diminue donc moins la résolution spatiale qu’un moyennage uniquement spatial. Le filtre de Quegan [QUEGAN et YU, 2001] est un filtre spatio-temporel, qui permet un tel compromis entre perte de résolution spatiale et temporelle. Il attribue à chaque pixel la valeur

$$J_k = \langle I_k \rangle \times \frac{1}{N} \sum_{t=1}^N \frac{I_t}{\langle I_t \rangle}$$

où I_k est un pixel d’une acquisition k , N est le nombre total d’acquisitions et $\langle I \rangle$ est la moyenne de I dans un voisinage spatial donné. Nous avons appliqué ce filtre à toutes les images S1 GRD de l’année 2019, avec une fenêtre spatiale de 50mx50m. Puis nous avons produit une moyenne mensuelle de ces images pour chaque mois de 2019. Nous avons calculé l’image $\frac{VV}{VH}$ pour chaque mois. Enfin nous avons converti toutes les images en décibels⁹.

Nous avons également produit des moyennes annuelles pour chaque polarisation et chaque type d’orbite, sans appliquer de filtre spatial, du fait de la profondeur de la série temporelle.

NISAR

Le satellite NISAR (NASA-ISRO Synthetic Aperture Radar) a été déployé à l’été 2025 et propose des images en bande L (24 cm) polarisée horizontalement, à une résolution de 20 m par 20 m pour les produits dits de niveau 2, que nous avons utilisés. Cette polarisation permet d’atteindre le sol même dans

7. Il s’agit d’images orthorectifiées et donnant l’intensité du signal radar rétrodiffusé pour chaque pixel.

8. Le choix de cette plateforme a été fait pour permettre l’automatisation du téléchargement et l’application de filtres et de moyennes à un grand nombre d’images sur serveur avant téléchargement. Ce qui n’était pas possible via OpenEO notamment.

9. $I_{db} = 10 \times \log_{10}(I_{lin})$ avec I_{db} , l’intensité de rétrodiffusion radar en décibels et I_{lin} l’intensité linéaire.

des zones de végétation dense [MCDONALD et al., 2024]. Ces images sont particulièrement prometteuses pour identifier les zones inondées sous des canopées, notamment dans des forêts tropicales. Un sol non inondé sous une canopée présente principalement une réflexion dite de volume, qui a la particularité de renvoyer un signal à la fois fort en co-polarisation et en polarisation croisée. Si le sol devient inondé, la réflexion de l'onde radar sur l'eau étant spéculaire, elle aura plus de chance de se faire en double rebond (eau puis végétation). Ce type de réflexion retourne un signal plus fort en co-polarisation qu'en polarisation croisée [HÜBINGER et al., 2026]. Le rapport entre intensité en co-polarisation et polarisation croisée est donc utile pour détecter les sols inondés sous canopée.

La mission NISAR fournit des images de rétrodiffusion radar géocodées et corrigées du terrain en intensité, ainsi que des images de cohérence de phase, entre deux acquisitions consécutives, du signal rétrodiffusé en copolarisation. La cohérence de phase est un dérivé de l'interférométrie SAR et est essentiellement un produit scalaire normalisé du signal radar complexe de la même zone géographique, à deux dates différentes. En tant que tel, il est une mesure de la similitude de la phase d'une région géographique entre deux dates. Cette cohérence est généralement faible sur l'eau libre et la végétation et forte sur les zones fixes comme les sols nus ou les villes. Pour la bande L de NISAR, les zones inondées sous canopée ont également une cohérence forte, ce qui est une autre manière de les identifier.

Les images NISAR sur la Haute-Garonne sont essentiellement disponibles depuis Juillet 2026¹⁰ et présentent des défauts, notamment en bord de tuile. Elles ne sont donc pas exploitables sur toute la zone d'étude. Nous avons appliqué un filtre de Qegan avec un noyau de 50 m par 50 m aux images d'orbite descendantes, qui étaient plus nombreuses que celles d'orbite ascendantes. Nous disposons de peu d'images d'orbite ascendantes (4) ce qui justifie l'utilisation d'une plus grande fenêtre de moyennage spatial. Après inspection visuelle des résultats obtenus avec différentes tailles de fenêtres spatiales, nous avons utilisé un noyau de 70 m par 70 m. Nous avons ensuite calculé une image de moyenne, d'écart-type, de minimum et de maximum pour chaque polarisation et orbite. Ces dernières images sont celles que nous avons utilisées en entrée du modèle *random forest* pour étudier leur apport (section 3.2).

Nous avons récupéré les images de cohérence de l'onde HH entre les deux dates les plus proches. Nous avons supprimé toutes celles obtenues par comparaison d'images acquises à plus de 12 jours d'intervalle. Nous avons ensuite séparé les cohérences issues d'images acquises en orbite ascendant et descendant et calculé pour chaque groupe la moyenne, l'écart-type, le minimum et le maximum, pour les fournir également en entrée de la chaîne de traitement.

1.2.5 Données Topographiques

Nous avons utilisé le Modèle Numérique de Terrain (MNT) RGE Alti® de l'IGN, fourni avec des pixels de 1 m par 1 m. Nous avons rééchantillonné bilinéairement ce MNT à un espacement de pixel de 10 m par 10 m. Nous avons calculé la pente de ce MNT comme la norme de son gradient $\|\nabla\| = \sqrt{\frac{\delta z}{\delta x}^2 + \frac{\delta z}{\delta y}^2}$, où les dérivés partielles sont estimées par gradient de Sobel :

$$\frac{\delta z}{\delta x} = MNT * \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \times \frac{1}{8r}$$

$$\frac{\delta z}{\delta y} = MNT * \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} \times \frac{1}{8r}$$

Avec r , la résolution en mètres de notre MNT (dans notre cas, $r = 10$).

À partir de la méthode de cartographie des zones humides potentielles modifiée, présentée dans la section 2.2, nous avons également calculé l'Indice Topographique de Position, qui est la différence de l'altitude d'un point avec la moyenne de son voisinage à différents rayons. Nous avons utilisé des rayons de 50 m, 250 m et 500 m. Ces variables sont désignées respectivement comme *cuvette100m*, *cuvette500m* et *cuvette1000m* dans différents graphiques.¹¹

Nous avons également inclus le Modèle Numérique de Surface MNS Correl de l'IGN, que nous avons rééchantillonné bilinéairement à 10 m de résolution.

Nous avons enfin calculé le modèle numérique de hauteur comme la différence du MNS Correl et du RGE Alti®.

10. Pour certaines tuiles, quelques images remontant jusqu'à l'été 2025 sont également disponibles

11. Ce nom est maladroit de notre part, car les valeurs élevées de cette variable correspondent à des crêtes et non des cuvettes.

1.2.6 Information Temporelle

La méthode REAUZOH, sur laquelle nous nous appuyons, construit un individu par pixel de la grille de référence et par mois de l'année 2019. Nous reprenons la méthode d'encodage des coordonnées temporelles de chaque individu mensuel de cette méthode, consistant à ajouter à la représentation de chaque individu $\sin(\frac{m}{12} \times 2\pi)$ et $\cos(\frac{m}{12} \times 2\pi)$ où $m \in [1, 12]$ est le code numérique du mois.

Chapitre 2

Étude de la Discriminabilité par random forest

Nous présenterons d'abord l'implémentation d'une méthode cherchant à être la plus fidèle possible à la méthode REAUZOH (section 2.1), puis nous présenterons les modifications faites à cette méthode (section 2.2).

2.1 Reproduction de la méthode REAUZOH

2.1.1 Constitution du jeu de données

Sélection des cellules de référence de zones humides

La différence principale entre cette reproduction et la méthode originale réside dans le jeu de vérité terrain. La méthode mise au point par le Cerema, dans une communauté de communes normande, reposait sur des relevés ponctuels de terrain *ad hoc*. Comme détaillé précédemment, nous sommes quant à nous partis de polygones inventoriés comme zones humides.

Nous avons commencé par récupérer les pixels de la grille de référence unique construite pour ce stage, qui correspondent à des zones humides dans l'inventaire de 2016. Dans la mesure où l'inventaire dont nous disposons est de grande ampleur, nous n'avons pas besoin de maximiser le nombre de pixels de notre jeu de vérité terrain. Nous avons donc fait le choix restrictif de ne garder que les pixels qui sont intégralement compris dans les polygones de référence. La rastérisation de couches vectorielles complexes peut être assez longue. Nous avons donc pris le parti de ne pas rastériser les polygones selon les outils classiques mais d'implémenter un algorithme un peu plus spécifique à notre situation¹.

Pour chaque polygone, cet algorithme :

1. le convertit en UTM31N.
2. récupère le rectangle englobant le polygone reprojété.
3. convertit les coordonnées géographiques du rectangle englobant en coordonnées matricielles de la manière suivante.

Soit P la matrice de passage des coordonnées matricielles homogènes dans notre grille de référence en coordonnées UTM31N homogènes, associée à toute image géoréférencée^a :

$$P = \begin{bmatrix} a & b & c \\ d & e & f \\ 0 & 0 & 1 \end{bmatrix}$$

1. La plus-value principale de cet algorithme est que l'on peut rastériser les zones humides en parallèle, permettant de tirer parti des serveurs de calcul multi-CPU sur lesquels sont exécutés nos scripts.

Soit X la matrice des coordonnées homogènes du rectangle englobant de forme

$$X = \begin{bmatrix} lon_{x1} & \cdots & lon_{xn} \\ lat_{x1} & \cdots & lat_{xn} \\ 1 & \cdots & 1 \end{bmatrix}$$

où les points x_i sont les points du rectangle englobant. On obtient alors les coordonnées matricielles dans la grille de référence en calculant $P^{-1}X$, puis en arrondissant les coordonnées obtenues à l'entier le plus proche.

a. Cette matrice est telle que chaque pixel de la grille de référence est espacé de $\begin{bmatrix} a \\ d \end{bmatrix}$ du pixel suivant de même ligne et de $\begin{bmatrix} b \\ e \end{bmatrix}$ du pixel suivant de même colonne. Le pixel de coordonnées matricielles $\begin{bmatrix} 0 \\ 0 \end{bmatrix}$ a comme coordonnées projetées $\begin{bmatrix} c \\ f \end{bmatrix}$.

4. reconstruit les rectangles associés à chaque pixel inclus dans le rectangle englobant.
5. filtre uniquement les pixels inclus dans les polygones initiaux, via les outils d'intersections spatiales implémentés dans la librairie python *geopandas*.
6. repasse les carrés sélectionnés en coordonnées géographiques en appliquant cette fois ci PX
7. On supprime les doublons dus au fait qu'un nombre important de rectangles englobants de polygones de zones humides se chevauchent.

La définition administrative française des zones humides exclut les zones d'eau libre (rivière, lac,...) et les zones imperméabilisées. Nous avons donc réimplémenté la méthode utilisée dans REAUZOH, consistant à agréger les différentes couches de la BD TOPO® de l'IGN recouvrant ces deux types de surface et à supprimer les pixels de zones humides les intersectant.

Nous obtenons de l'ordre de 300 000 pixels de zones humides sur la zone d'étude, ce qui est environ 25 fois plus que pour la méthode REAUZOH. Nous avons pu constater que pour ne pas saturer la RAM dont nous disposons, ultérieurement dans le processus, il fallait se limiter à 150 000 cellules de référence de zones humides et 150 000 cellules de référence de zones non humides. Nous tirons donc uniformément 150 000 pixels parmi les 300 000 candidats.

Sélection des cellules de référence de non zones humides

Une des difficultés méthodologiques de notre étude est que nous ne disposons pas d'un jeu de référence de régions garanties comme non zones humides. Nous avons donc choisi de nous appuyer sur la Cartographie Nationale des Zones Humides (CNZH), produite par PatriNat et présentée en introduction.

Comme on l'a vu, cette cartographie s'appuie sur des données géologiques, topographiques et hydrologiques, pour déterminer des probabilités qu'un pixel soit une zone humide. Nous avons pris les pixels masqués dans cette cartographie, car considérés comme zone imperméable ou en eau et les pixels considérés comme en dessous du seuil de 30% de probabilité d'être une zone humide². Cette méthode permet de fournir peu de faux négatifs dans le jeu de référence du modèle mais au prix d'un fort biais topographique. En effet, les pixels de faible probabilité de zone humide de la cartographie PatriNat, sont des pixels placés dans des zones drainantes (pentes, crêtes,...) et non dans les vallées. On introduit donc un biais topographique fort dans la constitution du jeu de données.

Nous avons tiré uniformément 150 000 cellules parmi les pixels de faible probabilité de zones humides ou considérés comme d'eau libre ou imperméabilisés. Nous obtenons ainsi $2 \times 150\,000$ pixels en tout dans le jeu de référence. Comme expliqué précédemment et comme schématisé sur la figure 2.1, pour tenir compte de la variabilité saisonnière des zones humides, un grand nombre de bandes issues d'acquisitions satellitaires que nous fournissons au modèle, sont des bandes mensuelles. Pour chaque cellule de référence, on construit donc 12 individus représentant chacun un mois de l'année 2019.

Le jeu de données final contient donc environ $12 \times 2 \times 150\,000 = 3.6 \times 10^6$ d'individus.

2.1.2 Chaîne de traitement de la reproduction de la méthode REAUZOH

Une fois obtenu notre jeu de données de référence, nous avons appliqué une chaîne de traitement, résumée dans la figure 2.1, se voulant la plus similaire possible à la méthode développée durant le projet REAUZOH [OLIVEIRA-SANTOS et al., 2025].

2. Seuil utilisé par PatriNat pour produire une cartographie seuillée.




FIGURE 2.1 – Diagramme de la chaîne de Traitement de la reproduction de la méthode REAUZOH





FIGURE 2.2 – Pourcentage de l'importance par permutation cumulée des variables d'entrée

1. Nous avons d'abord séparé le jeu de données en un jeu d'entraînement et un jeu de test de mêmes tailles.
2. Pour optimiser les hyperparamètres, nous avons eu recours à la recherche de grille. Pour ce faire, on a d'abord divisé le jeu d'entraînement en trois. On entraîne alors un *random forest* sur deux de ces sous-jeux et on calcule son rappel sur le troisième, non utilisé dans l'entraînement. On répète l'opération trois fois, sur les trois combinaisons possibles de sous-jeux (méthode dite de validation croisée). La moyenne des trois rappels obtenue est la métrique que nous utiliserons pour déterminer la meilleure combinaison d'hyperparamètres.
3. Pour ne garder que les variables les plus pertinentes pour le modèle, on calcule alors l'importance par permutation de chaque variable. L'importance par permutation d'une variable X est la différence entre une métrique de performance d'un *random forest* sur un jeu de test et sur le même jeu avec X mélangée aléatoirement. En l'occurrence, l'opération est répétée 10 fois pour une meilleure fiabilité du résultat. On obtient alors le graphique suivant, décrivant les importances par permutation de chaque variable (2.2).
4. Une fois déterminés les hyperparamètres et les variables à conserver, on peut entraîner un modèle *random forest*. Comme mentionné en introduction, le *random forest* est un type de modèle très utilisé pour la détection de zones humides pour deux raisons principales. Premièrement, c'est un modèle capable d'ingérer un grand nombre de variables prédictives de nature très différentes, ainsi qu'un jeu d'entraînement de grande taille, en restant économe en calcul. Deuxièmement, c'est un modèle qui ne nécessite pas de paramétrisation *a priori* de la distribution statistique des classes ou de définir des règles selon des connaissances expertes. C'est également un modèle ayant une bonne capacité de généralisation, plutôt que de sur-apprentissage de son jeu d'entraînement. Il est donc non seulement performant mais aussi adapté à une reproduction dans différents contextes par des personnes sans connaissances en écologie des zones humides. Nous détaillons le fonctionnement de cet algorithme en annexe B.



(a) Superposition des zones humides prédites et des pentes

(b) Superposition des zones humides prédites et de l'indice topographique de position

FIGURE 2.3 – Illustration de la confusion du modèle entre crêtes et cuvettes

2.1.3 Validation et Inférence du modèle

Pour produire une cartographie des zones humides potentielles à partir du modèle entraîné obtenu, on infère celui-ci sur toute la zone d'étude pour chaque mois et on assigne chaque pixel à sa classe majoritaire mensuellement. On réalise enfin un tamisage de l'image, pour ne conserver que les groupes de pixels 8-connexes de plus de 10 pixels³.

Le jeu de test, séparé en amont du jeu d'entraînement, nous permet de calculer les métriques usuelles, dérivées de la matrice de confusion, résumées dans le tableau 2.1.⁴

TABLE 2.1 – métriques du classifieur random forest

métrique	Non Zone Humide	Zone Humide	moyenne
précision	85%	81%	83%
rappel	81%	86%	83%
F1-Score	83%	83%	83%

Ces métriques sont difficiles à interpréter sans inférence globale sur la zone d'étude. Un F1-Score moyen de 0.83 est largement plus faible que celui de 0.92 de la méthode REAUZOH en Normandie mais cela est cohérent avec le fait que notre zone d'étude est plus vaste et notre jeu de données plus important. Il faut également interpréter ces métriques avec d'autant plus de précautions que notre jeu de référence négatif est peu fiable. En effet, l'inventaire de zones humides dont nous disposons est non exhaustif et nous ne disposons pas d'un inventaire de non zones humides. Ainsi, des métriques parfaites, proches de 100% de rappel et précision, ne seraient pas souhaitables, car elles suggéreraient que le modèle ne parvient pas à retrouver des zones humides non inventoriées. Enfin, ces métriques ne tiennent pas compte de la variabilité saisonnière. Une zone humide n'est pas nécessairement humide toute l'année et il est donc normal qu'un pixel labellisé zone humide ne soit pas forcément classé comme tel chaque mois.

L'étude des inférences montre que l'information de pente est très utilisée : les zones classées comme zones humides sont très largement situées dans les régions de faible pente. On peut suspecter que le modèle utilise la pente comme un indice de la nature en cuvette du paysage, propice à la formation des zones humides. Cela peut amener le modèle à confondre crête et vallée, tous les deux de pente nulle. La figure 2.3 montre que le modèle classe en zone humide des régions de faible pente, probablement interprétées comme des cuvettes, qui sont en fait des régions de crête. Pour éviter ce genre de confusions, il semble pertinent de fournir directement au modèle l'information de l'indice topographique de position multi-échelle (section 1.2.5), capable de distinguer crêtes et cuvettes.

On constate également un taux assez important de zones humides potentielles sur le nombre total de pixel. On peut remarquer que en montagne, quasiment toutes les vallées sont classées en zones humides.

3. Contrairement à la 4 connexité, la 8-connexité considère deux pixels en diagonale adjacents.

4. La précision d'une classe est calculée comme le rapport entre le nombre d'individus correctement prédits de cette classe et le nombre d'individus prédits au total dans la classe. Le rappel est le rapport entre le nombre d'individus correctement prédits d'une classe sur le nombre d'individus réellement dans cette classe. Le F1-Score est la moyenne harmonique de la précision et du rappel *i.e.* $2 \times \frac{\text{précision} \times \text{rappel}}{\text{précision} + \text{rappel}}$.

Le modèle semble donc avoir du mal à généraliser des règles valables à la fois pour la plaine toulousaine et les Pyrénées. Ce modèle prédit 25% de zones humides en Haute-Garonne, ce qui paraît trop important. Ce taux reste cependant similaire à celui obtenu dans la communauté de commune Cabbalr, avec la méthode REAUZOH et à celui obtenu par l’institut PatriNat et publié dans la CNZH. En effet, si on adopte un seuil de 0.5 sur les probabilités de cette cartographie, comme pour notre méthode, la CNZH classe 27% de la Haute-Garonne en zones humides.

2.2 Méthode Modifiée

Nous avons identifié quatre problèmes principaux de la méthode précédemment mise en place.

1) Nous n’avons pas mis en place de gestion de l’auto-corrélation spatiale. La méthode développée antérieurement à ce stage n’avait pas à prendre en compte l’auto-corrélation spatiale, car son jeu de vérité terrain était un jeu de données ponctuel provenant d’inventaires *ad hoc*. Les points d’inventaire étaient donc déjà espacés entre eux. Ces conditions ne sont plus vérifiées pour notre jeu de référence.

2) Nous n’avons pas vérifié avoir atteint des maximums locaux dans notre optimisation d’hyperparamètres. Cela est principalement dû à l’inefficacité d’une méthode d’optimisation systématique comme la recherche de grille.

3) La zone d’étude (toute la Haute-Garonne) semble trop grande et trop variée. Nous avons donc cherché à la réduire en une zone d’étude plus cohérente.

4) Le problème le plus préoccupant que nous avons identifié, au regard des objectifs de notre méthode, est la trop faible utilisation des variables mensuelles par le modèle, qui privilégie les variables topographiques et les moyennes annuelles dérivées d’acquisitions Sentinel-1, comme l’illustre la figure 2.2. Cela compromet un des objectifs de cette méthode qui est de s’appuyer sur des variables diachroniques. Nous avons identifié trois causes possibles à cette mauvaise prise en compte des bandes mensuelles :

- La sélection de dimensions par seuil sur l’importance par permutation, qui élimine d’emblée la plupart des variables mensuelles. Cette méthode défavorise les bandes redondantes en diluant leur importance. Les bandes optiques et leurs indices sont très nombreuses, ce qui dilue en conséquence leur importance individuelle.
- L’échantillonnage des pixels de non zones humides parmi les probabilités nulles de la CNZH. Cette méthode incite vraisemblablement le modèle à retrouver les zones drainantes à partir des bandes topographiques et incite donc le modèle à survaloriser ces bandes.
- La présence de faux positifs dans notre jeu de données, du fait de la variabilité saisonnière. La méthode sur laquelle nous nous appuyons crée un vecteur pour chaque mois de l’année 2019, pour chaque pixel labellisé zone humide. Le *random forest* est ensuite entraîné à identifier tous ces vecteurs comme zones humides. Or, la variabilité saisonnière des zones humides implique que ces pixels ne sont pas forcément qualifiables comme tel toute l’année, ce qui est donc source de confusion dans le jeu de données et pour le modèle.

Les modifications que nous avons apportées visent à répondre à ces problèmes.

2.2.1 Constitution du jeu de données

Partionnement de la zone d’étude

Nous avons pu noter que le modèle était particulièrement mauvais dans les Pyrénées. Les grandes chaînes de montagne induisent des contraintes méthodologiques pour l’utilisation de données satellitaires. En effet, les pentes créent des ombres et des surexpositions très marquées sur les images SAR. L’exposition solaire des pentes crée également des grands écarts sur les images de température de surface, dont nous souhaitons ultérieurement estimer l’apport. Dans une moindre mesure, des phénomènes d’ombres existent également sur les images Sentinel-2, qui sont acquises autour de 10h du matin, quand le soleil est encore potentiellement bas. Enfin, les zones humides sont vraisemblablement plus déterminées par la topographie dans les Pyrénées qu’en plaine et il semble donc inadapté d’entraîner un seul modèle à identifier des zones humides dans ces deux milieux à la fois. Nous avons donc restreint notre zone d’étude en ne conservant que les pixels situés à moins de 500m d’altitude.

Atténuation des Faux Positifs

Déneigement du jeu de vérité terrain

Nous avons postulé que l’enneigement est une source importante et facile à atténuer de faux positifs : le modèle ne peut pas utiliser les variables satellitaires pour identifier une zone enneigée inventoriée comme




FIGURE 2.4 – Diagramme de la chaîne de traitement modifiée pour constituer les jeux de données




FIGURE 2.5 – Histogramme du NDSI de l'image L3A Sentinel 2 de Février 2019

humide. Nous avons calculé l'indice de neige par différence normalisée (NDSI)⁵ de l'image L3A du mois de février 2019 sur notre zone, qui est une image présentant des régions enneigées. L'histogramme du NDSI obtenu (figure 2.5) montre clairement deux modes à la fois concentrés et espacés, ce qui confirme qu'un seuil sur cet indice est une bonne manière de distinguer, à peu de frais, les pixels enneigés des autres. À partir de cet histogramme, nous avons fixé un seuil de 0.4 sur le NDSI, à partir duquel un individu labellisé zone humide est supprimé. L'analyse de l'image de NDSI seuillé à 0.4 montre une bonne discrimination de la neige, malgré une classification des plans d'eau en zone enneigée. Ce comportement imprévu du NDSI n'est par chance pas un problème dans notre cas, puisque les zones d'eau libre ne peuvent, par définition, pas être des zones humides. La suppression des individus de $NDSI \geq 0.4$ diminue de 11% le jeu de données classé zone humide. Cette proportion significative laisse supposer que l'enneigement pouvait être une source de confusion ou *a minima* de bruit important.

Sélection des 6 mois les plus discriminables pour chaque pixel classé zone humide

La deuxième méthode que nous avons implémentée pour supprimer des faux positifs du jeu de données, a consisté à chercher pour chaque pixel classé zone humide, les 6 mois qui étaient les plus contrastés par rapport aux pixels non zone humide. Nous avons choisi le seuil de 6 mois dans la continuité de la méthode REAUZOH, qui considère un pixel comme zone humide pour une année donnée, seulement si il est classé au moins 6 mois sur 12 en zone humide par *lerandom forest*. Le postulat de notre méthode est donc que nous ne détecterons que les zones humides qui ressemblent suffisamment à des zones humides au moins 6

5. $\frac{Vert-PI}{Vert+PI}$ avec PI , une bande captée dans le Proche Infrarouge. Parmi les bandes de proche infrarouge disponibles, on utilise la bande 11 de Sentinel 2.




FIGURE 2.6 – Diagramme en barre du pourcentage d’individus de chaque mois supprimé

mois dans l’année.

Pour trouver les 6 meilleurs représentants de chaque pixel, nous avons entraîné un *random forest* sur le jeu de données d’entraînement constitué et dont on a déjà réduit les dimensions (étape ultérieure décrite dans la section 2.2.2). Pour chaque individu, on obtient la proportion des arbres de décision ayant classé cet individu en zone humide. On sélectionne alors les 6 mois avec la plus forte proportion pour chaque pixel. L’idée étant de sélectionner les représentants d’un pixel qu’un *random forest* arrive le mieux à distinguer du jeu de données négatif. La figure 2.6 montre le pourcentage d’individus d’un mois donné supprimés par cette méthode. Ce diagramme semble ne pas particulièrement faire ressortir de tendance saisonnière, contrairement à ce qu’on aurait pu croire. Cela suggère que cette méthode est plus pertinente que de ne garder que les mois d’automne et de printemps par exemple, durant lesquels la probabilité qu’une zone humide soit asséchée est moindre. On peut notamment supposer que les zones humides non asséchées en été, sont d’autant plus contrastées et donc discriminables des non zones humides.

Méthode d’échantillonnage des pixels de non zones humides

La méthode de constitution de jeu de données négatif utilisée dans notre première chaîne de traitement permettait de maximiser nos chances de ne pas avoir de faux négatifs dans notre jeu de données. Cependant, elle maximisait également la reproduction des biais de la CNZH, fondée sur une approche géomorphologique. Par construction, les zones de probabilité nulle d’être des zones humides selon cette cartographie sont très majoritairement des zones drainantes (pentes ou crêtes). Cela introduit un fort biais, diminuant les chances que notre modèle détecte les zones humides plus éloignées de cours d’eau et l’incitant à utiliser davantage les variables topographiques que satellitaires.

Nous avons donc modifié la méthode d’échantillonnage du jeu de données des non zones humides pour pondérer la probabilité d’être choisi comme représentant des zones non humides par la probabilité de ne pas être une zone humide selon la CNZH. Une première approche aurait par exemple été de tirer un sous jeu de données où chaque pixel est tiré avec sa probabilité de ne pas être une zone non humide. On pourrait alors tirer uniformément le nombre de pixels souhaités dans ce sous-jeu de données. Cette méthode serait cependant mauvaise, car elle ne corrigerait pas les asymétries de représentation des différentes probabilités dans le jeu de données d’origine. La figure 2.7 montre ainsi que si des pixels de faibles probabilités de ne pas être des zones humides étaient sur-représentés dans la zone d’étude, on les sur-représenteraient également dans l’échantillon final.

Ce que l’on aimerait plutôt c’est qu’il soit n fois plus probable de tirer uniformément dans notre échantillon un pixel avec une probabilité de ne pas être une zone humide n fois plus grande qu’un autre pixel. Formellement, on veut donc que la densité de probabilité f définie entre 0 et 1 de la variable aléatoire $X_{znh} : \Omega \rightarrow [0, 1]$, donnant la probabilité qu’un individu tiré au hasard dans notre échantillon ne soit pas une zone humide selon la CNZH, soit une fonction linéaire, d’intégrale 1, soit $f : x \rightarrow 2x \quad \forall x \in [0, 1]$.

Pour mettre cette idée en pratique, nous avons commencé par fixer à 100% la probabilité d’être des zones humides des pixels inventoriés comme zone humide dans notre jeu de vérité terrain. De cette manière, on s’assure qu’ils ne soient jamais tirés dans le jeu de vérité terrain négatif. Nous fixons également à 0% la probabilité que les pixels du masque de zones imperméabilisées ou d’eau libre soient des zones




FIGURE 2.7 – Illustration des limites d'une méthode naïve d'échantillonnage




FIGURE 2.8 – Diagramme en barres (a) et diagramme en barres cumulé (b) des probabilités de ne pas être une zone humide des individus de l'échantillon tiré.

humides. On calcule le complémentaire de cette carte pour obtenir une carte des probabilités de ne pas être une zone humide.

Nous avons ensuite quantifié les probabilités de cette dernière carte, en arrondissant les probabilités, exprimées en pourcentage, à l'entier supérieur. Ainsi, une probabilité en pourcentage $P_i \in [0, 100]$ sur la carte quantifiée, correspond à l'ensemble des probabilités en pourcentage $[P_i - 1, P_i]$ de la CNZH. Nous avons ensuite échantillonné cette cartographie quantifiée en tirant pour chaque probabilité p , discrète, le nombre d'individus permettant de vérifier deux conditions :

1. le diagramme en bâton des probabilités quantifiées de l'échantillon doit être linéaire.
2. la taille de l'échantillon doit être de 150 000, pour respecter nos contraintes informatiques.

Pour ce faire, il nous suffit, pour tout $P_i \in [0, 100]$ de tirer $\frac{150000}{\sum_{n=0}^{100} n} \times P_i$.

Cependant, certaines probabilités sont trop peu représentées dans la cartographie dont nous disposons. Lorsque c'est le cas, nous reportons le déficit sur la probabilité supérieure, plutôt qu'inférieure. La logique étant de sur-représenter, plutôt que sous-représenter, les fortes probabilités de ne pas être des zones humides.

On obtient ainsi le diagramme en barre et le diagramme en barre cumulé de la probabilité de ne pas être une zone humide des individus de notre échantillon, présentés en figure 2.8. On peut voir sur le diagramme en barre un pic autour des probabilités de 15% qui correspond au fait qu'on a très peu de très faibles probabilités de ne pas être une zone humide dans la CNZH. Les effectifs de ces faibles probabilités sont donc reportés sur les probabilités plus fortes. On peut cependant voir, sur le diagramme cumulé, qu'on ne dépasse jamais l'optimum théorique cumulé, malgré ce pic.

Une fois cet échantillon obtenu, on peut appliquer un filtre gaussien sur l'image des pixels faisant parti de l'échantillon, pour estimer la densité d'échantillonnage locale en Haute-Garonne. La carte obtenue (Figure 2.9) montre bien des asymétries de densité. Cependant, les zones de forte densité d'échantillonnage




FIGURE 2.9 – Visualisation de la densité d'échantillonnage des pixels du jeu de données négatif

ne sont pas les zones de forte probabilité de ne pas être des zones humides mais les zones avec un fort ratio entre l'effectif à tirer dans leur plage de probabilité et le nombre total de pixel de cette plage de probabilité dans l'image. Ainsi, les zones de forte probabilité de ne pas être des zones humides étant très nombreuses sur la carte, elles sont peu densément échantillonnées. Les zones de fort échantillonnage que l'on voit sont en fait des zones de probabilités faible de ne pas être des zones humides (entre 15% et 30% de probabilité), qui sont, elles, peu représentées sur la zone d'étude et spatialement concentrées.

Gestion de l'auto-corrélation spatiale

L'auto-corrélation spatiale désigne la similitude entre un pixel et les pixels de son voisinage. Elle est généralement importante sur des images satellitaires. Ainsi, deux pixels tirés dans une même zone inventoriée comme zone humide ont des chances significatives de se ressembler. Or, la validation d'algorithmes de classification est fondée sur une séparation entre un jeu d'entraînement et un jeu de test, qui doivent être indépendants les uns des autres : un pixel ne doit pas être présent dans les deux jeux à la fois. Si on tire aléatoirement les individus du jeu de test et d'entraînement, une forte auto-corrélation spatiale crée une situation de pseudo-réplication : un pixel qui est presque une copie d'un autre peut ne pas faire parti du même jeu. Dès lors, une matrice de confusion et ses métriques associées sont très difficiles à interpréter, car un modèle ayant simplement sur-appri son jeu d'entraînement, pourra tout de même avoir d'excellentes performances sur le jeu de test. Ce phénomène est assez dommageable également pour la phase d'optimisation des hyperparamètres. Durant cette phase, on utilise une validation croisée sur trois plis, issus du jeu d'entraînement, pour estimer la performance de chaque combinaison d'hyperparamètres testée. Si les plis ne sont pas suffisamment indépendants, on récompensera donc les combinaisons d'hyperparamètres qui permettent un sur-apprentissage du jeu d'entraînement. Cela correspond principalement, pour un *random forest*, à d'importantes profondeurs de décision et un faible nombre minimum d'échantillons par division et par feuille.

Pour limiter ce problème, les individus classés zone humide sont groupés selon la zone humide inventoriée dont ils proviennent et les individus classés non zone humide sont groupés selon des carreaux de 5 km de côté. Autrement dit, deux jeux de données supposés indépendants entre eux (le jeu de test et d'entraînement et les trois plis du jeu d'entraînement), ne contiennent pas de pixels positifs provenant de la même zone humide et de pixels négatifs du même carreau de 5 km de côté.




FIGURE 2.10 – Diagramme de la chaîne de production de la cartographie des zones humides potentielles

2.2.2 Chaîne de production de la cartographie des zones humides potentielles

Réduction de dimension par Analyse en Composantes Principales des variables

A chaque nœud d'un arbre de décision, un *random forest* n'a accès qu'à un sous ensemble, tiré aléatoirement, des variables du jeu de données, pour choisir un seuil sur l'une d'elles. Dans notre cas, ce sous ensemble a une taille valant la racine carrée du nombre de variables. Si on fournit l'ensemble des 42 variables d'entrées, chaque nœud n'aura accès qu'à 6 variables tirées aléatoirement. Si beaucoup de variables sont de faible utilité, la pertinence de chaque arbre s'en trouve diminuée. Corollairement, si beaucoup de variables sont très corrélées entre elles, cela biaise le *random forest* vers une sur-utilisation de ces variables dupliquées.

Pour contenir ce phénomène, d'autant plus important que notre jeu de données contient beaucoup de variables redondantes, nous avons besoin d'implémenter une méthode de sélection ou de réduction de dimension. La technique utilisée, dans la méthode que notre stage vise à améliorer, consistait à ne conserver que les variables dépassant un certain seuil d'importance par permutation. Cependant, cette méthode pénalise les variables redondantes. Si deux variables sont très corrélées, l'importance par permutation des deux s'en trouve diminuée, car si le *random forest* ne peut plus accéder à l'une d'elles, il pourra se reporter sur l'autre.

Nous avons donc souhaité remplacer cette méthode de seuil sur l'importance par permutation par un passage de la base de notre jeu de données vers la base de ses composantes principales, suivi d'un seuil sur le taux de variance projetée cumulé des composantes principales. Le passage d'un jeu de données dans la base des composantes principales repose sur une technique couramment utilisée pour réduire les dimensions d'un jeu de données, nommée Analyse en Composantes Principales (ACP).

L'Analyse en Composante Principale est un changement de système de coordonnées d'un jeu de données, qui vise à en proposer une représentation dans un système orthonormé incluant le vecteur de plus forte variance projetée, puis le vecteur de plus forte variance projetée orthogonal au précédent et ainsi de suite jusqu'à atteindre le nombre de dimensions du jeu de données. Par extension, cette analyse permet une réduction de dimension, en ne conservant que les vecteurs de base ayant la plus grande variance projetée. C'est donc une manière de ne pas simplement supprimer des variables inutiles mais plutôt de résumer un grand nombre de variables. En annexe C nous utilisons la méthode d'optimisation sous contrainte lagrangienne pour montrer que trouver les vecteurs qui vérifient cette définition revient à trouver les vecteurs propres de la matrice de covariance.




FIGURE 2.11 – F1-Score moyen par validation croisée en fonction des hyperparamètres

Avant d’opérer ce changement de repère, nous avons centré et réduit nos variables⁶. En plus de ne pas artificiellement sur-estimer la variance relative de variables de grande amplitude, on peut émettre l’hypothèse que le centrage et la réduction peut conférer plus de robustesse dans le transfert à d’autres contextes spatiaux ou temporels. Par exemple, si le *random forest* est entraîné sur une année plutôt froide et pluvieuse, il va peut être apprendre que le NDVI d’une zone humide au mois d’août doit se situer au dessus d’un seuil assez élevé. Si on infère ce même *random forest* sur une année chaude et sèche, ce seuil élevé ne sera peut-être plus pertinent, une fois appliqué à une végétation globalement plus stressée. En centrant et réduisant les variables, les seuils appris par le *random forest* ne seront plus en valeur absolue mais relatifs à la variance globale de la variable. Le modèle pourra apprendre des règles comme "le NDVI doit être supérieur à 1.2 écart-type de la moyenne". Ce qui aura tendance à être plus stable dans des contextes où les valeurs absolues se situent dans des intervalles décalés et contractés par rapport au contexte du jeu d’entraînement.

Nous avons sélectionné les composantes principales de plus forte variance, dont la somme des variances projetées est supérieure à 90% du total des variances projetées. Pour le jeu de données d’entraînement en plaine (altitude inférieure à 500m), nous obtenons 13 composantes principales, au lieu des 42 initiales.

Optimisation des Hyperparamètres par Tree-Structured Parzen Estimator

La méthode que nous cherchons à améliorer, optimisait les hyperparamètres du *random forest* par recherche de grille. Cela consiste à tester toutes les combinaisons d’hyperparamètres pré-définies. En pratique, nous avons restreint les hyperparamètres dont on explore les combinaisons à quatre, qui nous semblent les plus impactants sur les performances du modèle : le nombre d’arbres de décision, la profondeur maximale de chaque arbre, le nombre minimal d’individus que le modèle peut sous diviser par un nouveau seuil et le nombre minimal d’individus autorisé sur les feuilles de chaque arbre. Le nombre de combinaisons à tester par recherche de grille est donc $\prod n_i$ avec n_i le nombre de valeurs testables pour un hyperparamètre i . Ce nombre de combinaisons devient vite prohibitif. Certains hyperparamètres affectent beaucoup plus que d’autres les performances du modèle. Plutôt que de tester systématiquement chaque combinaison, il est plus pertinent de se concentrer sur l’affinage des hyperparamètres qui semblent impacter fortement le résultat et de ne pas tester des valeurs d’hyperparamètre dont il est vraisemblable qu’elles donneront des résultats inférieurs à des combinaisons déjà effectuées⁷.

Le Tree-Strucutred Parzen Estimator [WATANABE, 2023] est un algorithme d’optimisation des hyperparamètres qui permet justement cela et qui est d’utilisation courante dans le champ du *machine learning*. Nous proposons une explication détaillée de son fonctionnement, dans un cas unidimensionnel simplifié en annexe D.

Pour évaluer le score d’une combinaison, nous avons utilisé le f1-score moyen sur les 3 plis qui partitionnent le jeu d’entraînement. La figure 2.11 montre la valeur de ce score pour chaque valeur testée d’hyperparamètres. On peut voir que ce score atteint un plateau à partir d’une profondeur maximale d’environ 20 et un nombre d’arbres de 400. Cela nous permet de considérer, avec une bonne fiabilité, qu’une modification des hyperparamètres déterminés par cet algorithme n’apporterait qu’un gain négligeable de performance.

6. centrer et réduire une variable consiste à soustraire à cette variable sa moyenne et à la diviser par son écart-type.

7. Par exemple, si la performance du modèle est croissante selon les valeurs d’un hyperparamètre déjà testées, il semble peu efficace de quand même tester des valeurs de cet hyperparamètre plus faibles que celles déjà testées.

Détermination du taux de votes d'arbres du *random forest* optimal

Une fois que nous avons réduit le nombre de dimensions de notre jeu de données initial et déterminé la combinaison d'hyperparamètres optimale, nous pouvons entraîner un modèle *random forest* sur notre jeu d'entraînement. On peut alors optimiser la proportion minimale de votes pour la classe zone humide pour assigner un individu à cette classe. Pour ce faire, nous avons calculé les taux de vrais positifs et de faux positifs associés à chaque seuil possible. Le taux de vrais positifs (TVP) est équivalent au rappel de la classe positive, soit le rapport entre les individus positifs bien classés et le nombre total d'individus positifs. Le taux de faux positifs (TFP) est le rapport d'individus négatifs mal classés sur le nombre total d'individus négatifs. C'est donc le complémentaire à un du rappel de la classe négative. Pour calculer ces taux, nous devons prendre une précaution. Notre méthode de cartographie des zones humides potentielles classe un pixel en zone humide si 6 mois sur 12 de cet individu sont classés en zones humides. Pour calculer par exemple le TVP pour un seuil donné, on cherche donc le nombre de pixels, labellisés zone humide, dont au moins 6 individus mensuels dépassent ce seuil, divisé par le nombre de pixels labellisés zone humide total.

On calcule alors ces TVP et TFP, fondés sur la classe majoritaire par pixel, pour chaque pourcentage d'arbres classant un individu en zone humide. Nous avons choisi de conserver le seuil de proportion d'arbre classant en zone humide qui maximise TVP-TFP et qui est atteint dans notre cas pour 42% d'arbres classant un individu mensuel en zone humide. Cette proportion est donc significativement inférieure au vote majoritaire (>50%), qui est le seuil par défaut que nous avons utilisé dans la méthode initiale.

2.2.3 Validation et Inférences

Validation après classement par classe mensuelle majoritaire

De la même manière que dans l'optimisation du taux de vote, nous avons utilisé une méthode de validation qui ne se fait pas au niveau de l'individu mensuel mais plutôt par classe majoritaire pour les individus mensuels de chaque pixel. Cela nous permet d'avoir une validation qui correspond à notre cartographie finale, qui ne classe un pixel en zone humide que si au moins six de ses individus mensuels sont classés en zone humide. En adoptant cette méthode de validation, on peut dériver de la matrice de confusion les rappels, précision et f1-score résumés dans la table 2.2.

TABLE 2.2 – métriques du classifieur random forest

métrique	Non Zone Humide	Zone Humide	moyenne
précision	82%	88%	85%
rappel	89%	81%	85%
F1-Score	86%	85%	85%

Ces métriques sont globalement similaires à celles obtenues dans la méthode initiale mais cela est encourageant. En effet, la méthode initiale n'introduisait pas de gestion de l'auto-corrélation spatiale, ce qui augmentait artificiellement les performances de classification sur le jeu de test. En outre, la méthode d'échantillonnage des non zones humides que nous avons mise en place les rend plus difficiles à distinguer des zones humides. Ces métriques, fondées sur la classe majoritaire de chaque pixel, sont également plus interprétables, car elles se rapportent directement à la performance de la classification des pixels de Haute-Garonne et non des individus mensuels issus de chaque pixel.

ROC et AUC

La courbe dite *Receiver Operating Characteristics* (ROC) et l'aire sous cette courbe (ROC-AUC), sont également des métriques pertinentes pour estimer la performance de notre modèle et en particulier sa supériorité par rapport à une classification aléatoire. La courbe ROC est une courbe du TVP en fonction du TFP, qui est présentée pour notre méthode dans la figure 2.12. La première bissectrice représente la performance moyenne qu'aurait une classification aléatoire de nos pixels. L'écart à la première bissectrice, valant TVP-TFP, est ainsi le gain du modèle par rapport à l'aléatoire, raison pour laquelle nous avons utilisé le maximum de cette fonction comme seuil optimal pour classer un individu en zone humide.

Une propriété du TFP est qu'il est strictement décroissant en fonction du seuil de taux d'arbres classants en zone humide. Une autre propriété de cette courbe, qui dérive de cette première, est que son intégrale, abrégée AUC, est la probabilité qu'un pixel labellisé zone humide tiré aléatoirement, ait une probabilité d'être une zone humide, selon notre méthode, plus forte qu'un pixel non zone humide tiré




FIGURE 2.12 – Courbe ROC du jeu de test

aléatoirement. Cette probabilité serait de 0.5 pour une classification aléatoire et elle est de 0.93 pour notre classification. Cette métrique est un bon indicateur pour statuer sur la discriminabilité radiométrique et topographique de nos deux jeux de données.

Interdépendance des variables prédictives et des probabilités d'être une zone humide selon le modèle

Nous aimerions être en mesure de savoir quelles règles le modèle apprend. Une méthode pour tenter de visualiser le profil des zones humides appris par le modèle, pour une composante principale donnée, est de réaliser une estimation de densité par noyau gaussien (technique souvent désignée par son nom anglais *gaussian KDE*) des points (x_i^k, y_i) où x_i^k est la valeur de la composante principale k pour un individu i et y_i est la probabilité que l'individu i soit une zone humide selon notre modèle⁸. Cependant, nous aimerions également avoir une mesure de la dépendance entre les valeurs d'une CP donnée et la probabilité donnée par le modèle, analogue à une corrélation. Malheureusement, les corrélation de Pearson ou de Spearman, ne permettent de restituer que des dépendances monotones entre des variables. Or, une première analyse de nos cartes de densité montre que la plupart des règles apprises par le modèle ne sont pas des corrélations monotones. Nous avons donc eu recours à la théorie de l'information et à la métrique de l'information mutuelle qui en est dérivée. Nous détaillons le raisonnement derrière la formule de l'information mutuelle⁹ et nous justifions le fait que l'information mutuelle de deux variables X et Y est une métrique permettant de mesurer la dépendance de X et Y dans l'annexe E.

Pour chaque composante principale (CP) de notre jeu de données, on peut ainsi produire une figure analogue à la figure 2.13. Sur ces figures, on donne une mesure d'à quel point la probabilité d'être une zone humide selon le modèle est dépendante de la CP, analogue à une mesure de corrélation, sous la forme de son pourcentage de l'information mutuelle de toutes les composantes avec la probabilité d'être une zone humide. Ces figures incluent également la carte de densité de la probabilité en fonction de la composante, normalisée en colonne¹⁰, qui permet d'appréhender les profils radiométriques réellement appris par le modèle. Ces figures présentent aussi les 6 variables initiales avec lesquelles cette CP est la plus corrélée, positivement ou négativement, ainsi que la valeur de cette corrélation.

Un résultat frappant de ces figures est que la CP qui a l'information mutuelle la plus importante et

8. On identifie le taux d'arbres classants un individu en zone humide à une probabilité d'être une zone humide selon le modèle.

9. $I(X, Y) = H(X) - H(X|Y)$ avec $I(X, Y)$ l'information mutuelle de X et Y et $H(X)$ l'entropie de X au sens de la théorie de l'information.

10. Autrement dit, une densité pour une valeur de CP et une probabilité donnée est divisée par la somme de toutes les densités pour cette même valeur de CP. Cela permet de corriger la densité en un point, de la sur ou sous représentation de certaines plages radiométriques sur la zone d'étude.




FIGURE 2.13 – Visualisation de la relation entre la composante principale 0 et la probabilité d’être une zone humide selon le modèle




FIGURE 2.14 – Visualisation de la relation entre la composante principale 2 et la probabilité d’être une zone humide selon le modèle

de loin (38% de l’information mutuelle cumulée), est une CP corrélée avec des variables issues des bandes optiques des satellites Sentinel-2, comme on le voit dans la figure 2.13. Cela est un grand changement avec la méthode précédente, pour laquelle c’était de loin la pente et les bandes non diachroniques qui primaient. Le graphique produit pour cette CP permet de voir que plus le NDVI et le NDWI sont forts et plus la bande bleue et 12 de Sentinel-2 et le *Brightness Index* (BI) sont faibles, plus le modèle prédit de fortes probabilités d’être une zone humide. Ce résultat est encourageant mais il laisse penser que notre modèle confond peut-être les zones humides avec les simples zones de forte végétation, qui correspondent aux zones de fort NDVI.

Le graphique montrant la relation entre la CP corrélée avec des variables Sentinel-1, de plus forte information mutuelle (fig 2.14) montre en revanche une relation en cloche. On voit que le modèle associe des très faibles probabilités aux très fortes rétrodiffusions Sentinel-1, qui correspondent à des zones urbanisées. Les zones de faible rétrodiffusion sont également associées à des zones de faible probabilité : elles correspondent généralement à de l’eau libre ou à du sol nu. Les valeurs intermédiaires plutôt fortes, sont celles associées à des bonnes probabilités d’être une zone humide selon le modèle.

Comparaison de l’inférence obtenue avec l’inférence de la méthode initiale

La figure 2.15 est une composition colorée de la cartographie des zones humides potentielles, obtenue par la méthode initiale, présentée dans la section précédente et la méthode modifiée, présentée ici. La




FIGURE 2.15 – Composition Colorée de la carte des zones humides potentielles obtenue par la méthode initiale (bande rouge) et la méthode modifiée (bande verte)

	rappel	precision	f1_score
non zone humide	0.64	0.7	0.67
zone humide	0.91	0.89	0.9
moyenne	0.78	0.8	0.79

TABLE 2.3 – Métriques uniquement sur les pixels de fort NDVI

méthode modifiée est largement plus discriminante dans les zones topographiquement ambiguës, c'est-à-dire les vallées, en particulier celle de la Garonne. C'est ce qui explique la dominante de rouge dans ces régions, qui correspondent à des zones supprimées par la méthode modifiée. Quand on s'attarde précisément sur les zones supprimées et ajoutées par la présente méthode, on constate que les zones supprimées sont des zones de champ et les zones ajoutées sont des zones de végétation dense, de bois ou de forêt. La meilleure utilisation des bandes satellitaires est probablement responsables de la suppression de zones agricoles dans la nouvelle cartographie

Cependant, comme le suggère l'inférence du modèle mais aussi l'analyse des informations mutuelles, il semble y avoir une sur-détermination de la probabilité d'être une zone humide, selon le modèle, par la densité de végétation. Notre modèle semble donc confondre zone humide et zone fortement végétalisée.

Comme le montre la figure 2.16, les zones humides de l'inventaire dont nous nous servons ont un NDVI nettement plus important que le reste de la Haute-Garonne. Nous avons utilisé un seuil à moins deux écarts-types de la moyenne du NDVI des zones humides, pour sélectionner les pixels de la Haute-Garonne d'un NDVI qui leur est comparable. On peut alors calculer la matrice de confusion et les métriques qui en dérivent, uniquement sur les pixels de notre jeu d'entraînement supérieurs à notre seuil de NDVI (figure 2.3). On voit que le rappel des non zones humides n'est plus que de 64%, contre 89% sur tout le jeu de test, ce qui montre bien que notre modèle a tendance à sur-classer les pixels de fort NDVI en zone humide.




FIGURE 2.16 – Histogrammes normalisés du NDVI des zones humides et du reste de la Haute-Garonne, calculés au mois de Juin 2019

Chapitre 3

Étude de l'apport de nouvelles données satellitaires à la détection de zones humides par *random forest*

3.1 Étude de l'apport de la température de surface Landsat

Plusieurs articles, dont MURO et al. (2018) et LOIZEAU-WOOLLGAR et al. (2025), montrent que les produits satellitaires de température de surface (TS) sont des sources d'information prometteuses pour caractériser les zones humides. Cependant ces articles ne quantifient par l'apport marginal de la température de surface à une méthode de détection qui inclurait des variables topographiques, optiques sans infrarouge thermique et SAR.

Nous avons ainsi appliqué notre méthode de cartographie des zones humides potentielles, sur le même jeu de données que la méthode générale présentée précédemment (section 2.2), en ajoutant les médianes saisonnières issues des acquisitions Landsat de 2019 à 2022 et en supprimant les pixels qui n'étaient pas contenus dans l'intersection des deux tuiles Landsat, que nous avons retenue comme zone d'étude méthodologiquement robuste (voir section 1.2.3). Nous avons également ajouté l'image d'amplitude thermique de l'année 2019, dérivée des acquisitions ECOSTRESS. Nous avons ensuite ré-entraîné deux modèles en appliquant notre chaîne de traitement : un avec l'information de TS et un autre, témoin, sans cette information¹.

Nous avons répété dix entraînements pour chaque méthode. Les figures 3.1 et 3.2 résument les métriques moyennes de ces dix entraînements, arrondies au millièème, avec leur intervalle de confiance à 95%,

1. On ne peut pas directement comparer les métriques obtenues avec la TS à celles obtenues pour toute notre zone d'étude (section 2.2), car la zone d'étude n'est pas la même.




FIGURE 3.1 – Informations mutuelles des variables d’entrée avec les probabilités d’être une zone humide selon un modèle entraîné avec les TS

calculé en utilisant l’écart-type des dix entraînements comme estimation de l’erreur standard. On peut y voir que les modèles entraînés avec TS semblent avoir un meilleur rappel des non zones humides et un moins bon rappel des zones humides. Ce qui indiquerait que l’ajout de ces bandes conduit le modèle à classer un peu moins de pixels en zones humides. Cependant, on peut voir que le f1-score moyen, avec et sans TS est identique, avec une faible incertitude, ce qui indique que la TS, telle qu’elle est incluse dans notre chaîne de traitement, ne contribue pas à la qualité de la classification.

métrique	Non Zone Humide	Zone Humide	moyenne
précision	$77.8 \pm 0.3\%$	$85.3 \pm 0.1\%$	$81.5 \pm 0.2\%$
rappel	$84.7 \pm 0.2\%$	$78.6 \pm 0.4\%$	$81.6 \pm 0.3\%$
F1-Score	$81.1 \pm 0\%$	$81.8 \pm 0.1\%$	$81.4 \pm 0.1\%$

TABLE 3.1 – Métriques moyennes et intervalles de confiance à 95% des modèles entraînés avec les bandes de TS

métrique	Non Zone Humide	Zone Humide	moyenne
précision	$78.1 \pm 0.4\%$	$84.8 \pm 0.2\%$	$81.5 \pm 0.3\%$
rappel	$84 \pm 0.3\%$	$79.1 \pm 0.6\%$	$81.6 \pm 0.5\%$
F1-Score	$80.9 \pm 0.1\%$	$81.9 \pm 0.2\%$	$81.4 \pm 0.2\%$

TABLE 3.2 – Métriques moyennes et intervalles de confiance à 95% des modèles témoins

Notre hypothèse est que la TS apporte une information pertinente pour la détection des zones humides mais redondante vis à vis des nombreuses bandes et indices optiques déjà présents dans le jeu de données. Nous appuyons notamment cette hypothèse sur le graphique des informations mutuelles des variables d’entrée avec les probabilités d’être une zone humide selon un modèle entraîné avec les TS présenté dans la figure 3.1. Cette figure montre que les TS Landsat ont une information mutuelle moyenne avec les probabilités du modèle, suggérant que cette bande est aussi informative que la plupart des autres.

3.2 Étude de l’apport des images NISAR

Nous avons également réalisé un entraînement avec et sans les images NISAR (bande L et polarisation horizontale). Nous avons utilisé des variables dérivées des images de cohérence de phase entre deux acquisitions et des images de rétrodiffusion, comme détaillé dans la section 1.2.4. Les images NISAR présentent, au moment de ce travail, des trous entre tuiles, des défauts manifestes au bord de celles-ci, ainsi qu’un nombre d’acquisitions très variables pour chacune d’elles. Nous avons donc défini à la main, une sous zone d’étude, incluse dans la Haute-Garonne, qui apparaît de qualité homogène sur les images dont nous disposons.

Comme précédemment, nous avons répété dix entraînements avec et sans ces images. Les tableaux 3.3 et 3.4, présentent les métriques moyennes sur ces dix entraînements, arrondies au millièrme, avec leur intervalle de confiance à 95%.

Ces tableaux montrent notamment un gain moyen de 0.4% de f1-score, assez significatif par rapport à la marge d’erreur de l’intervalle de confiance. Cela suggère que ces bandes améliorent réellement, bien

métrique	Non Zone Humide	Zone Humide	moyenne
précision	$72.3 \pm 0.4\%$	$88 \pm 0.2\%$	$80.1 \pm 0.1\%$
rappel	$88.1 \pm 0.3\%$	$72 \pm 0.6\%$	$80.1 \pm 0.2\%$
F1-Score	$79.8 \pm 0.1\%$	$79.6 \pm 0.3\%$	$79.7 \pm 0.2\%$

TABLE 3.3 – Métriques moyennes et intervalles de confiance à 95% des modèles entraînés avec les bandes NISAR

métrique	Non Zone Humide	Zone Humide	moyenne
précision	$71.6 \pm 0.4\%$	$88.2 \pm 0.2\%$	$79.9 \pm 0.1\%$
rappel	$88.5 \pm 0.3\%$	$70.9 \pm 0.7\%$	$79.7 \pm 0.2\%$
F1-Score	$79.6 \pm 0.1\%$	$79 \pm 0.3\%$	$79.3 \pm 0.2\%$

TABLE 3.4 – Métriques moyennes et intervalles de confiance à 95% des modèles témoins

que pas énormément, les prédictions du modèle.

Comme nous l’avons fait pour notre méthode générale, on peut également produire les matrices de confusion uniquement sur des pixels de fort NDVI, qui sont les pixels que notre modèle a du mal à discriminer. Sur les dix entraînements pour chaque méthode, on obtient un f1-score moyen de $70.3 \pm 0.1\%$ sur ces pixels pour le modèle entraîné avec les images NISAR, contre $69.1 \pm 0.1\%$ pour la méthode témoin. On peut donc supposer que la capacité de la bande L en polarisation horizontale à pénétrer plus profondément dans les canopées, permet au modèle d’améliorer ses prédictions sur les zones de forte végétation, qui sont des zones particulièrement confuses pour le modèle. Cependant, en sélectionnant, comme on le fait, les pixels de fort NDVI de notre jeu de test, on obtient un nombre assez faible d’individus non zone humide. De plus, le gain de performance, bien que significatif par rapport à l’intervalle de confiance à 95%, reste faible. L’estimation de l’amélioration de la détection sous canopée grâce à ces images nécessiterait donc une étude plus approfondie.

On peut également analyser, comme précédemment, l’importance par permutation et l’information mutuelle de chaque composante principale, ainsi que les variables avec lesquelles elles sont les plus corrélées, informations que nous avons résumées dans la figure 3.5. On peut notamment y voir que la composante principale de loin la plus importante par permutation et également avec le plus d’information mutuelle avec les prédictions du modèle, n’est plus corrélée au NDVI comme précédemment mais à des bandes NISAR de polarisation HV. On peut voir sur la figure 3.2, que le modèle apprend une relation croissante et monotone : plus le retour en polarisation croisée est fort, plus le modèle prédit une forte probabilité de zone humide. Cela montre que le modèle n’apprend pas à chercher des zones inondées, marquées par un retour en double rebond, dont le signal rétrodiffusé est dominé par la copolarisation [HÜBINGER et al., 2026] mais plutôt de la rétrodiffusion de volume, qui augmente avec la densité de végétation et l’humidité.

Cette étude montre que les images NISAR sont prometteuses pour la détection de zones humides, même lorsque celles-ci ne sont pas inondées. Elles semblent notamment pouvoir améliorer les performances du modèle dans les zones de végétation dense, sur lesquelles le modèle n’est pas très bon. Il faut rappeler que nous disposons d’images assez peu nombreuses et principalement concentrées sur deux mois. L’apport d’une série temporelle annuelle complète est donc encore à préciser.

Chapitre 4

Synthèse des Résultats, Limites et Perspectives

4.1 Apports

La méthode finale que nous avons mise en place, se démarque de la méthode initialement implémentée par une meilleure prise en compte de toutes les bandes fournies en entrée. La figure 2.2 montre que quelques variables topographiques concentraient l’essentiel de l’importance par permutation pour

CP	taux IP	taux IM	type	rang 1	rang 2	rang 3
0	43.4%	23.3%	variable	nisar_d_hv_mean	ascending_hv_min	ascending_hv_mean
			corrélation	0.93	0.93	0.93
1	18.1%	15.2%	variable	ndwi	ndvi	bsi
			corrélation	0.73	0.68	-0.68
17	9.4%	4%	variable	pente	nisar_asc_coherences_max	nisar_des_coherences_min
			corrélation	0.58	0.28	-0.26
10	9%	7.8%	variable	cuvette500m	cuvette1000m	cuvette100m
			corrélation	0.76	0.69	0.41
2	5.8%	2.1%	variable	b8	bi2	cos_temporel
			corrélation	0.73	0.72	-0.54
5	4.4%	7.7%	variable	nisar_d_hh_hv_mean	nisar_d_hh_hv_max	nisar_d_hh_hv_min
			corrélation	0.56	0.55	0.51
3	3.8%	10%	variable	nisar_asc_coherences_min	nisar_asc_coherences_mean	nisar_des_coherences_min
			corrélation	0.61	0.58	0.57
7	2.6%	3.2%	variable	mns	mnt	nisar_des_coherences_std
			corrélation	0.48	0.48	0.36
8	1.4%	3.6%	variable	mndwi	bi1	vv-vh_des
			corrélation	0.56	-0.33	0.32
13	0.9%	1.7%	variable	sin_temporel	nisar_des_coherences_max	cos_temporel
			corrélation	0.85	-0.24	-0.2
4	0.5%	4.3%	variable	ascending_hh_hv_mean	ascending_hh_hv_max	ascending_hh_hv_min
			corrélation	0.74	0.72	0.69
11	0.4%	2.5%	variable	nisar_asc_coherences_std	mndwi	vv-vh_des
			corrélation	0.35	-0.35	0.31
9	0.2%	0.7%	variable	vv_des_year_mean	vv_asc_year_mean	vv_des
			corrélation	0.44	-0.43	0.42
18	0.2%	1.5%	variable	vv-vh_asc	ascending_hv_std	cuvette100m
			corrélation	0.27	-0.25	0.24
16	0.2%	2.5%	variable	cuvette100m	evi	nisar_des_coherences_max
			corrélation	0.53	0.43	0.29
14	0	2.3%	variable	nisar_des_coherences_max	nisar_des_coherences_std	cuvette100m
			corrélation	0.44	0.37	-0.33
15	0	2.2%	variable	evi	cuvette100m	pente
			corrélation	0.82	-0.36	0.21
6	-0.2%	4.8%	variable	mns	mnt	vv_des
			corrélation	0.54	0.54	0.41
12	-0.2%	1%	variable	nisar_asc_coherences_std	nisar_des_coherences_std	nisar_asc_coherences_min
			corrélation	0.74	-0.41	-0.35

Taux IP = Pourcentage de l'Importance par Permutation cumulée

Taux IM = Pourcentage de l'Information Mutuelle cumulée

TABLE 3.5 – Variables les plus corrélées avec chaque CP classées par importance par permutation.




FIGURE 3.2 – Estimation de la densité par noyau gaussien, normalisée en colonne, de la relation entre la probabilité d'être une zone humide selon le modèle et la CP 0, corrélée principalement aux bandes NISAR HV.




FIGURE 4.1 – Importances par permutation des composantes principales et information mutuelle de ces composantes avec la probabilité d’être une zone humide selon le modèle

le modèle initial. En revanche, la figure 4.1 montre que plus de composantes principales, qui résument chacune différentes variables, ont une importance par permutation significative dans la méthode modifiée. En outre, la composante principale la plus importante de cette méthode est principalement corrélée avec une bande satellitaire, alors que les variables les plus importantes de la méthode initiale étaient topographiques. Cette revalorisation des bandes satellitaires conduit comme on l’a vu à la suppression de zones de champ dans la méthode finale (section 2.2.3). Cette revalorisation est probablement due en partie à l’extraction de caractéristique par Analyse en Composante Principale, qui se montre donc être une méthode pertinente pour tirer parti de nombreuses bandes de sources assez différentes. Une autre raison de cette revalorisation peut également être l’implémentation d’une méthode de tirage de pixels de non zones humides, pondéré par les probabilités de la CNZH. Cette méthode de sélection permet de fournir un jeu de données négatif plus complexe au modèle, qu’il est plus difficile de distinguer du jeu positif uniquement par des variables topographiques.

Cependant, notre modèle reste peu discriminant sur les zones de fort NDVI. Il semble donc que la détection de zones humides sous un important couvert végétal, reste un point noir des méthodes fondées sur des images satellitaires. Ce résultat est cohérent avec le constat fait par GRIMSON et al. (2026), qui notent que les méthodes de détection de zones humides par satellite sur-représentent les zones d’eau libre et sous-représentent les zones densément végétalisées.

Le lancement récent de la mission NISAR, dont les ondes radar sont capables de mieux pénétrer dans la canopée que la bande C de Sentinel-1, est à ce titre prometteur. Nous avons pu constater une amélioration des performances du modèle sur les pixels de fort NDVI, lorsqu’il était entraîné avec les images de cette mission. Cela nécessiterait cependant d’être confirmé par une étude plus approfondie.

On peut également constater que notre méthode produit des résultats assez complémentaires de ceux de la CNZH. Ainsi, la densité de détection de zone humide de notre méthode est plus proche de celle de notre inventaire que la CNZH. Cela confirme notamment que notre méthode permet de tirer parti d’inventaires locaux, alors que la CNZH, d’envergure nationale, présente parfois des trous à l’échelle régionale dans son jeu de données. En outre, notre méthode se montre plus discriminante dans les zones de vallées et moins discriminante dans les zones de forêt plus éloignées d’importants cours d’eau, comme le montre la figure 4.2. La complémentarité de ces deux visions du territoire peut être utile aux acteurs de la conservation des zones humides.




FIGURE 4.2 – Composition colorée des probabilités d’être une zone humide selon notre méthode (bande verte) et selon la CNZH (bande rouge)

4.2 Limites

Notre approche consistant à fournir au même modèle chaque mois de chaque pixel est peut-être une source de confusion pour le modèle. On peut émettre l’hypothèse que sur des variables avec une forte variation saisonnière, comme la température de surface, le fait que des individus aient le même label mais des valeurs très différentes, car à des saisons différentes, rend difficile d’utiliser cette variable pour distinguer nos deux classes¹. Ceci peut en partie expliquer pourquoi notre méthode n’a pas été améliorée par l’ajout de la température de surface. Des pistes pour remédier à cela seraient d’entraîner un modèle par mois, de centrer-réduire les variables mois par mois et non pour toute l’année et de ne pas inclure le cosinus et le sinus temporel dans l’ACP, pour garder ces variables intactes et plus facilement utilisables par le modèle.

Notre étude ne nous a pas permis de confirmer l’utilité de la TS pour la détection des zones humides, défendue par LOIZEAU-WOOLLGAR et al. (2025). Nous avons pu constater que les images ECOSTRESS manquaient de données pour construire des images d’amplitude thermique journalière à l’échelle d’une saison. Les images d’amplitude construites sur toute une année sont, quant à elles, probablement trop peu contrastées pour améliorer le modèle. Les médianes saisonnières Landsat semblent porteuses d’information mais redondantes par rapport aux autres bandes optiques déjà incluses dans la méthode et qui ont une meilleure résolution spatiale et temporelle.

De nombreuses autres méthodes de pré-traitement des séries temporelles de TS pourraient être explorées. Il serait intéressant de réaliser une ACPF², comme LOIZEAU-WOOLLGAR et al. (2025). Cependant, la zone d’étude de cet article est beaucoup plus restreinte que la nôtre. Notre plus grande zone d’étude implique que des pixels risquent d’avoir des dates d’acquisition valides moins cohérentes que dans leur étude, du fait des nuages et de la taille de fauchée. Pour les images ECOSTRESS, acquises à des heures très variables, faire une ACPF de telles séries, peut ainsi conduire à retrouver ces différences d’heures d’acquisition plus que des différences dans les profils thermiques réels. L’ACPF de séries temporelles

1. Par exemple, on aimerait que le modèle puisse apprendre que les zones humides ont une TS inférieure aux non zones humides. Cependant, dans le même jeu de données, les individus zone humide d’été ont des valeurs de TS supérieures aux individus non zone humide d’hiver.

2. Analyse en Composante Principale Fonctionnelle

est également très dépendante du profil météo de l'année d'entraînement³. C'est donc une méthode qui peut difficilement être appliquée sur une année différente de l'année d'entraînement, ce qui contrevient à l'objectif de suivi inter-annuel de notre méthode.

Une autre limite tien au fait qu'un intérêt de la cartographie que nous produisons, serait d'assister les agents de l'environnement dans un effort d'inventaire des zones humides, en leur fournissant une pré-localisation. Cependant, notre méthode utilise un inventaire déjà de grande ampleur, ce qui diminue le besoin de pré-localisation. La performance de notre modélisation avec un jeu d'entraînement plus chiche n'est quant à elle pas établie, tout comme sa performance sur une autre zone géographique ou une autre année. En outre, si un des objectifs de notre méthode est de pouvoir suivre l'état des zones humides d'année en année, pour alerter plus finement sur les pressions qu'elles subissent, une telle utilisation soulève de nombreux problèmes méthodologiques, qui nécessiteraient une étude à part entière. En effet, notre cartographie ne permet qu'une pré-sélection de zones plus susceptibles que d'autres d'être des zones humides. Le saut sémantique pour passer du constat d'une évolution d'une telle cartographie à un discours sur l'évolution des zones humides réelles n'a rien d'évident.

Notre travail pourrait également bénéficier d'une d'expertise en écologie des zones humides, pour estimer la cohérence écologique de la cartographie que nous produisons.

4.3 Perspectives

Une perspective intéressante pour améliorer les prédictions d'un modèle sur une année différente de celle de son entraînement, serait d'utiliser des données météorologiques, en plus des cosinus et sinus temporels que nous fournissons. Le modèle pourrait ainsi apprendre à adapter ses seuils, non pas seulement en fonction de la période de l'année mais aussi en fonction du profil pluviométrique et de température d'un mois donné. Cela rendrait possiblement les prédictions du modèle plus robustes sur des années où les pics de chaleur ou de pluviométrie seraient décalés par rapport à ceux de son année d'entraînement. Les données de réanalyse de la température de l'air, de la pluviométrie et de l'humidité du sol, de la base de données SAFRAN, produite par Météo-France, seraient indiquées pour fournir ce genre d'information météorologique au modèle. On peut également citer la piste développée par ZHANG et al. (2024), qui consiste à construire un jeu de vérité terrain inter-annuel, à partir d'un jeu de données non diachronique, en appliquant un modèle de détection de changement pour éliminer les pixels du jeu de vérité terrain qui semblent avoir changé de nature.

Enfin, de nombreuses études, dont ZHANG et HAN (2023), montrent le caractère prometteur d'architectures de segmentation sémantique, fondées sur des mécanismes attentionnels, pour la détection des zones humides. La prise en compte de la variabilité saisonnière des zones humides et en particulier la meilleur détection de zones humides de végétation basse, comme des prairies humides, est un problème relativement analogue à la détection des types de culture, pour laquelle de nombreux modèles de segmentation sémantique existent. A ce titre, l'adaptation des modèles de détection de cultures utilisant le modèle d'attention temporelle UTAE [GARNOT et LANDRIEU, 2021], pré-entraînés sur le jeu de données FLAIR-HUB de l'IGN [GARIOUD et al., 2026] est une perspective prometteuse. L'entraînement ou l'adaptation d'architectures d'apprentissage profond, utilisant l'attention, nécessite cependant de très grandes capacités de calcul. Cela contrevient à la facilité de reproduction et à l'échelle régionale au cœur de notre méthode de cartographie.

Une autre perspective pourrait donc être de tirer parti des *embeddings* ou "encodages", produits par des modèles de fondation géographique et qui fournissent pour chaque pixel, des représentations sémantiques enrichies de nombreuses informations dérivées de l'analyse de séries temporelles et du contexte spatial, sans avoir à réaliser de réentraînement. Ces *embeddings* pourraient pallier le fait que notre classification par *random forest* soit à l'échelle du pixel, sans prendre en compte le contexte spatial des individus qu'il classe. Nous utilisons également assez peu la dynamique temporelle de nos variables satellitaires. Deux modèles de fondation récents semblent pertinents pour enrichir notre modélisation. Le premier est le modèle Tessera [FENG et al., 2026], développé par l'Université de Cambridge, qui ne prend pas en compte le contexte spatial mais encode finement l'évolution temporelle de chaque pixel. Le second est le modèle Prithvi-EO-2.0 [SZWARCMAN et al., 2025], développé par la NASA et IBM, qui encode à la fois le contexte spatial et temporel.

Si l'apprentissage profond est indéniablement une perspective intéressante, sa supériorité sur le *random forest* pour notre objectif n'est pas acquise. En effet, la vocation de notre méthode est de s'adapter à des

3. Une ACPF va par exemple beaucoup "coller" aux dates exactes de vagues de chaleur, si ces vagues expliquent beaucoup de variances dans les différentes séries temporelles. Si on applique l'ACPF sur une autre année, ces dates exactes de vagues de chaleur ont d'importantes chances de ne plus être pertinentes.

échelles régionales et de tenter de ne pas reproduire les biais des inventaires existants. L'apprentissage profond nécessite en général une quantité de données d'entraînement plus importante que les *random forest*, ce qui n'est pas forcément adapté à un contexte local. De plus, la modélisation plus fine, en tenant compte notamment du contexte spatial, pourrait tendre à coller d'autant plus aux types de milieux déjà présents dans l'inventaire et donc à en reproduire davantage les biais.

Conclusion

Notre méthode finale apporte des contributions aux quatre objectifs annoncés en introduction.

1. **Établir une méthode de cartographie à échelle régionale et facilement reproductible dans différents contextes, sans nécessité de connaissances expertes en zones humides, pour pallier les zones blanches des cartographies de petite échelle.** L'apport de notre méthode, par rapport à la méthode REAUZOH, pour la facilité de reproduction à échelle régionale, se situe principalement dans le fait de pouvoir utiliser directement des inventaires de terrain et de constituer un jeu de données négatif par tirage pondéré par les probabilités de la CNZH, disponible pour la France entière. Cette méthode permet de se passer de jeu de vérité terrain *ad hoc*, au prix d'une plus forte reproduction des biais de la CNZH.
2. **Établir une méthode tenant compte, dans sa modélisation, de la variabilité saisonnière des zones humides.** Notre contribution à cet aspect réside d'abord dans le revalorisation des bandes satellitaires, par rapport aux bandes topographiques, permis notamment par l'extraction de caractéristiques par ACP. Un apport important de notre méthode à cet objectif consiste également en la pré-sélection des six mois les plus discriminables de chaque pixel de zone humide, pour réaliser l'entraînement du *random forest* final, ainsi que dans l'élimination des individus enneigés, sur la base du NDSI. On peut enfin citer l'implémentation d'une validation par classe majoritaire des mois de chaque pixel et pas seulement une validation à l'échelle de chaque individu. Cette méthode de validation permet notamment de tenir compte de la variabilité saisonnière dans la phase d'optimisation des hyperparamètres. Il est cependant possible que l'intégration des cosinus et sinus temporels dans l'ACP et le centrage et la réduction des variables d'entrée à l'échelle de l'année, plutôt que mois par mois, affaiblisse la capacité de modélisation de la variabilité saisonnière de notre méthode.
3. **Établir une méthode reproductible d'années en années, pour permettre le suivi de ces milieux dégradés.** L'apport de notre méthode à cet objectif est encore une fois le revalorisation des bandes satellitaires, les bandes topographiques ne permettant pas la comparaison d'années en années. Toutefois, nous n'avons pas eu le temps de tester notre modèle sur d'autres années que son année d'entraînement.
4. **Établir une méthode représentant mieux les zones humides sous végétation dense et éloignées de cours d'eau.** Notre méthode détecte plus de zones humides dans des zones de forêt éloignées de grandes vallées que la CNZH. Toutefois, notre modèle a un mauvais rappel des non zones humides de fort NDVI. Notre étude tend donc à confirmer les limites de modèles fondés sur les images satellitaires pour identifier les zones humides sous fort couvert végétal [GRIMSON et al., 2026]. Nous avons pu montrer que les images NISAR, en bande L polarisée horizontalement, semblent permettre des améliorations de la détection des zones humides dans ces contextes, et ce même si les zones humides ne sont pas inondées.

Enfin, l'utilisation de données météorologiques, comme la pluviométrie ou la température de l'air, est une perspective prometteuse à explorer, pour tenter de fiabiliser les prédictions du modèle sur une année différente de son entraînement, dans une perspective de suivi inter-annuel des zones humides. L'utilisation de modèles de fondation géographiques semble également pertinente pour mieux tirer parti des séries temporelles satellitaires et ainsi améliorer la modélisation de la variabilité saisonnière. Ils pourraient aussi améliorer la prise en compte du contexte spatial, ce qui fournirait une représentation plus riche que

la représentation "au pixel" de notre *random forest*.

Bibliographie

- ADELI, S., SALEHI, B., MAHDIANPARI, M., QUACKENBUSH, L. J., BRISCO, B., TAMIMINIA, H., & SHAW, S. (2020). Wetland monitoring using SAR data : A meta-analysis and comprehensive review. *Remote Sensing*, 12(14), 2190.
- BREIMAN, L. (2001). Random forests. *Machine learning*, 45(1), 5-32.
- ECOTONE. (2013). *INVENTAIRE DES ZONES HUMIDES DE LA HAUTE-GARONNE PHASE 1 : PRE-INVENTAIRE* (rapp. tech.). Ecotone.
- ECOTONE. (2016). *INVENTAIRE DES ZONES HUMIDES SUR LE DEPARTEMENT DE LA HAUTE-GARONNE Phase 2 : Cartographie et caractérisation* (rapp. tech.). Ecotone.
- EFFAH, D., ZIA, A., AWRANGJEB, M., GAO, Y., & SARPONG, K. (2025). Advances in machine learning for wetland classification : a comprehensive survey of methods and applications. *Artificial Intelligence Review*, 59(1), 24.
- FENG, Z., ATZBERGER, C., JAFFER, S., KNEZEVIC, J., SORMUNEN, S., YOUNG, R., LISAIUS, M. C., IMMITZER, M., JACKSON, T., BALL, J., et al. (2026). Tessera : Temporal embeddings of surface spectra for earth representation and analysis. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 34818-34831.
- GARIOUD, A., GIORDANO, S., DAVID, N., & GONTHIER, N. (2026). FLAIR-HUB : Large-scale multimodal dataset for land cover and crop mapping. *ISPRS Journal of Photogrammetry and Remote Sensing*, 237, 271-300.
- GARNOT, V. S. F., & LANDRIEU, L. (2021). Panoptic segmentation of satellite image time series with convolutional temporal attention networks. *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, 4852-4861.
- GRENIER, M., LABRECQUE, S., GARNEAU, M., & TREMBLAY, A. (2008). Object-based classification of a SPOT-4 image for mapping wetlands in the context of greenhouse gases emissions : The case of the Eastmain region, Québec, Canada. *Canadian Journal of Remote Sensing*, 34(sup2), S398-S413.
- GRIMSON, R., PIEGARI, E., SALVIA, M., MINOTTI, P., NOMDEDEU, S., & KANDUS, P. (2026). Beyond open water : mapping the spectral and hydrological limits of Pampean wetlands classification with Landsat time series. *International Journal of Remote Sensing*, 47(3), 1448-1472.
- GUIDUGLI-COOK, M., RICHTER, S. C., SCOTT, B. J., & BROWN, D. R. (2017). Field-based assessment of wetland condition, wetland extent, and the National Wetlands Inventory in Kentucky, USA. *Wetlands ecology and management*, 25(5), 517-532.
- HE, Z., HE, D., MEI, X., & HU, S. (2019). Wetland classification based on a new efficient generative adversarial network and Jilin-1 satellite image. *Remote Sensing*, 11(20), 2455.
- HÜBINGER, C., FLUET-CHOUINARD, E., ESCOBAR, D., & JARAMILLO, F. (2026). Exploring the potential of using L-band InSAR for mapping flooded vegetation in tropical wetlands. *Remote Sensing of Environment*, 332, 115086.
- HULLEY, G. C., GÖTTSCHE, F. M., RIVERA, G., HOOK, S. J., FREEPARTNER, R. J., MARTIN, M. A., CAWSE-NICHOLSON, K., & JOHNSON, W. R. (2021). Validation and quality assessment of the ECOSTRESS level-2 land surface temperature and emissivity product. *IEEE Transactions on Geoscience and Remote Sensing*, 60, 1-23.
- JAMALI, A., & MAHDIANPARI, M. (2022). Swin transformer and deep convolutional neural networks for coastal wetland classification using sentinel-1, sentinel-2, and LiDAR data. *Remote Sensing*, 14(2), 359.
- JING, L., ZHOU, Y., ZENG, Q., LIU, S., LEI, G., LU, C., & WEN, L. (2020). Exploring wetland dynamics in large river floodplain systems with unsupervised machine learning : A case study of the Dongting Lake, China. *Remote Sensing*, 12(18), 2995.
- KAPLAN, G., & AVDAN, U. (2018). Monthly analysis of wetlands dynamics using remote sensing data. *ISPRS International Journal of Geo-Information*, 7(10), 411.

- KAPLAN, G., AVDAN, Z. Y., & AVDAN, U. (2019). Mapping and monitoring wetland dynamics using thermal, optical, and SAR remote sensing data. *Wetlands management : Assessing risk and sustainable solutions*, 87.
- LANE, C. R., LIU, H., AUTREY, B. C., ANENKHONOV, O. A., CHEPINOGA, V. V., & WU, Q. (2014). Improved wetland classification using eight-band high resolution satellite imagery and a hybrid approach. *Remote sensing*, 6(12), 12187-12216.
- LIN, Y., SHEN, M., LIU, B., & YE, Q. (2013). Remote sensing classification method of wetland based on an improved SVM. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, 40, 179-183.
- LOIZEAU-WOOLLGAR, L., RAPINEL, S., PELLEN, J., CLÉMENT, B., & HUBERT-MOY, L. (2025). Contribution of ECOSTRESS thermal imagery to wetland mapping : Application to heathland ecosystems. *ISPRS Journal of Photogrammetry and Remote Sensing*, 220, 649-660.
- MAHDAVI, S., SALEHI, B., GRANGER, J., AMANI, M., BRISCO, B., & HUANG, W. (2018). Remote sensing for wetland classification : A comprehensive review. *GIScience & remote sensing*, 55(5), 623-658.
- MAHDIANPARI, M., BRISCO, B., GRANGER, J., MOHAMMADIMANESH, F., SALEHI, B., HOMAYOUNI, S., & BOURGEAU-CHAVEZ, L. (2021). The third generation of pan-Canadian wetland map at 10 m resolution using multisource earth observation data on cloud computing platform. *IEEE journal of selected topics in applied earth observations and remote sensing*, 14, 8789-8803.
- MCDONALD, K., PODEST, E., STEINER, N., TESSER, D., ZIMMERMANN, R., NIESSNER, A., RIOS, M., URQUIZA, J. D., HUNEINI, R., DOWNS, B., et al. (2024). NISAR : Seeing beyond the trees to understand wetlands, forests and biodiversity. *IGARSS 2024-2024 IEEE International Geoscience and Remote Sensing Symposium*, 6775-6778.
- MURO, J., STRAUCH, A., HEINEMANN, S., STEINBACH, S., THONFELD, F., WASKE, B., & DIEKKRÜGER, B. (2018). Land surface temperature trends as indicator of land use changes in wetlands. *International journal of applied earth observation and geoinformation*, 70, 62-71.
- OFFICE FRANÇAIS DE LA BIODIVERSITÉ. (2026). *Les Zones Humides*. Consulté le 21 août 2026 à <https://ofb.gouv.fr/les-zones-humides>
- OLIVEIRA-SANTOS, N., BOUSQUET-BORRUT, E., DESEURE, M., PICHARD, O., KERLOC'H, B., & LAMPIN, C. (2025). *REAUZOH. Recensement, cartographie et suivi de l'évolution des Zones potentiellement Humides, Phase 2- Recensement et cartographie des zones potentiellement humides* (rapp. tech.). CEREMA Occitanie.
- POULIOT, D., LATIFOVIC, R., PASHER, J., & DUFFE, J. (2019). Assessment of convolution neural networks for wetland mapping with landsat in the central Canadian boreal forest region. *Remote Sensing*, 11(7), 772.
- QUEGAN, S., & YU, J. J. (2001). Filtering of multichannel SAR images. *IEEE Transactions on geoscience and remote sensing*, 39(11), 2373-2379.
- RAPINEL, S., PANHELLEUX, L., LEMERCIER, B., CHAMBAUD, F., GAYET, G., GUELMAMI, A., LAROCHE, B., VANACKER, R., & HUBERT-MOY, L. (2023, février). *Projet de cartographie nationale des milieux humides – Rapport méthodologique de la prélocalisation des milieux et des zones humides, de la cartographie des habitats et de l'évaluation des fonctions* (rapp. tech.) (Responsables de l'étude : Guillaume Gayet (agent OFB à PatriNat) et Rachel Vanacker (agent MNHN à PatriNat). Chef de l'équipe en charge du programme : Stanislas Wroza.). Patrinat (OFB-MNHN-CNRS-IRD). <https://mnhn.hal.science/mnhn-04292468>
- SEMIENIUK, C., & SEMIENIUK, V. (2016). Wetland classification : Hydrogeomorphic system. *The wetland book : I : Structure and function, management and methods*, 1-8.
- SLAGTER, B., TSENDBAZAR, N.-E., VOLLRATH, A., & REICHE, J. (2020). Mapping wetland characteristics using temporally dense Sentinel-1 and Sentinel-2 data : A case study in the St. Lucia wetlands, South Africa. *International Journal of Applied Earth Observation and Geoinformation*, 86, 102009.
- SOSZYNSKA, A., van der WERFF, H., HIERONYMUS, J., & HECKER, C. (2023). A new and automated method for improving georeferencing in nighttime thermal ECOSTRESS imagery. *Sensors*, 23(11), 5079.
- STEWART, A. J., ROBINSON, C., CORLEY, I. A., ORTIZ, A., LAVISTA FERRES, J. M., & BANERJEE, A. (2025). Torchgeo : deep learning with geospatial data. *ACM Transactions on Spatial Algorithms and Systems*, 11(4), 1-28.
- SZWARCMA, D., ROY, S., FRACCARO, P., GÍSLASON, O. E., BLUMENSTIEL, B., GHOSAL, R., DE OLIVEIRA, P. H., de SOUSA ALMEIDA, J. L., SEDONA, R., KANG, Y., et al. (2025). Prithvi-eo-2.0 : A versa-

- tile multi-temporal foundation model for earth observation applications. *IEEE Transactions on Geoscience and Remote Sensing*.
- WATANABE, S. (2023). Tree-structured parzen estimator : Understanding its algorithm components and their roles for better empirical performance. *arXiv preprint arXiv :2304.11127*.
- YUAN, S., LIANG, X., LIN, T., CHEN, S., LIU, R., WANG, J., ZHANG, H., & GONG, P. (2025). A comprehensive review of remote sensing in wetland classification and mapping. *arXiv preprint arXiv :2504.10842*.
- ZHANG, X., LIU, L., ZHAO, T., WANG, J., LIU, W., & CHEN, X. (2024). Global annual wetland dataset at 30 m with a fine classification system from 2000 to 2022. *Scientific Data*, 11(1), 310.
- ZHANG, X., & HAN, L. (2023). Accurate, automatic zero-shot wetland mapping from high resolution remote sensing imagery by prompting large foundation model (Segment Anything Model-SAM). *2023 IEEE Smart World Congress (SWC)*, 850-853.

Annexe

Annexe A

Images du nombre d'acquisitions Landsat par mois de l'année 2019




FIGURE A.1 – Images du Nombre d'acquisitions Landsat en Haute-Garonne des différents mois de 2019

Annexe B

Fonctionnement d'un *random forest*

Un *random forest* [BREIMAN, 2001] est un modèle constitué d'un ensemble d'arbres de décision binaires (figure B.1). Pour chaque arbre de décision, un échantillon du jeu d'entraînement est tiré. Pour le premier nœud de l'arbre, on tire aléatoirement un sous ensemble des variables de chaque individu. Puis, on détermine le seuil sur une de ces variables, qui permet de diviser le jeu de données en deux nouveaux nœuds, de sorte à minimiser la moyenne de l'indice de Gini de ces deux nœuds. L'indice de Gini est une mesure de "l'impureté" d'un nœud, calculée avec la formule $Gini = \sum_i p_i(1 - p_i)$, avec p_i la proportion d'individus de la classe i dans le nœud.

On redivise avec des seuils le jeu de données, un nombre fixé préalablement de fois (profondeur de décision), comme illustré sur le schéma B.1. Les derniers nœuds sont appelés des feuilles et sont toutes assignées à une classe. Ensuite, l'inférence d'un *random forest* consiste à appliquer tous les arbres de décision à chaque individu à classer. La prédiction du modèle pour un individu est alors généralement la classe qui est attribuée, par la majorité des arbres, à cet individu.

En introduisant de l'aléatoire dans les règles apprises, ce type de modèle est capable d'apprendre des règles de classification générales et a une bonne capacité à ne pas sur-apprendre son jeu d'entraînement.




FIGURE B.1 – Schéma d'un arbre de décision binaire

Annexe C

Théorie de l'Analyse en Composantes Principales

L'Analyse en Composante Principale est un changement de système de coordonnées d'un jeu de données, qui vise à en proposer une représentation dans un système orthonormé incluant le vecteur de plus forte variance projetée, puis le vecteur de plus forte variance projetée orthogonal au précédent et ainsi de suite jusqu'à atteindre le nombre de dimensions du jeu de données. Par extension, cette analyse permet une réduction de dimension, en ne conservant que les vecteurs de base ayant la plus grande variance projetée. C'est donc une manière de ne pas simplement supprimer des variables inutiles mais plutôt de résumer un grand nombre de variables.

Soit une matrice X_{nm} représentant notre jeu de données avec les n individus en ligne et les m variables en colonne. On note $X_c = X - \bar{X}$ la matrice représentant nos variables dont on soustrait leurs moyennes. Soit $\vec{u}$ un vecteur unitaire quelconque. La projection du jeu de données centré sur la droite qui porte ce vecteur s'écrit alors $X_c \vec{u}$. Puisque X_c est centré, la variance et la covariance ne sont que des produits scalaires de ces variables centrées, divisés par leur nombre de dimension. Par conséquent, la variance du jeu de données projeté sur $\vec{u}$ s'écrit $\frac{1}{m} (X_c \vec{u})^T X_c \vec{u}$ où m est encore une fois le nombre de variables.

Puisque $(A \times B)^T = B^T A^T$, on peut dès lors modifier l'expression ainsi :

$$\frac{1}{m} (X_c \vec{u})^T X_c \vec{u} = \frac{1}{m} \vec{u}^T X_c^T X_c \vec{u} = \vec{u}^T \frac{1}{m} X_c^T X_c \vec{u}$$

On peut alors remarquer que $X_c^T X_c$ est une matrice donnant le produit scalaire entre chaque variable centrée. Ainsi, $\frac{1}{m} X_c^T X_c$ est la matrice de covariance de X que l'on note C . Il est important de noter que cette variable est symétrique, puisque $Cov(x_1, x_2) = Cov(x_2, x_1)$ (où x_1 et x_2 sont des vecteurs représentant une variable).

On peut ainsi poser que la variance projetée dans une direction, dont $\vec{u}$ est un vecteur unitaire, s'écrit : $\vec{u}^T C \vec{u}$.

De là, le problème de l'ACP, consistant à commencer par trouver la direction portant le plus de variance du jeu de données revient à maximiser $\vec{u}^T C \vec{u}$ sous la contrainte $\vec{u}^T \vec{u} = 1$ (vecteur unitaire).

Un tel problème d'optimisation sous contrainte peut-être résolu en annulant le gradient du lagrangien des deux expressions. L'optimisation sous contrainte par annulation du gradient du Lagrangien, repose sur le fait que le maximum d'une fonction vérifiant une certaine contrainte sera toujours atteint en un point où l'hyperplan décrivant la contrainte est tangent à l'hyperplan d'isovaleurs de la fonction à maximiser. Or, le gradient est toujours orthogonal à l'hyperplan d'isovaleurs. Ainsi, en un point maximisant la fonction sous contrainte, les gradients de la fonction et de la fonction de contrainte sont alignés. En notant F la fonction à maximiser et G la fonction de contrainte, on peut donc dire que le point x^* maximisant la fonction vérifie $\nabla F(x^*) = \lambda \nabla G(x^*)$ avec $\lambda \in \mathbb{R}$.

Au lieu de trouver les points vérifiant cette équation, l'optimisation sous contrainte mobilisant le multiplicateur lagrangien procède en posant une expression dont l'annulation du gradient revient à la résolution de cette équation. Cette expression s'appelle le Lagrangien et se note $L = F - \lambda(G - b)$ où b est la contrainte que G doit vérifier.

Pour l'ACP, comme on l'a vu, la fonction à maximiser est $\vec{u}^T C \vec{u}$ et la fonction de contrainte est $\vec{u}^T \vec{u}$ avec $b = 1$. Le lagrangien de notre expression est donc $L = \vec{u}^T C \vec{u} - \lambda(\vec{u}^T \vec{u} - 1)$. Le vecteur $\vec{u}$ maximisant la variance, est un des vecteurs qui annule le gradient de cette expression. Pour trouver le gradient de L

selon $\vec{u}$, il faut se souvenir que, du fait de la commutativité de la covariance, C est symétrique. Dès lors,

$$\nabla L = 2C\vec{u} - 2\lambda\vec{u}$$

D'où

$$\nabla L = 0 \Leftrightarrow C\vec{u} = \lambda\vec{u}$$

On pourrait montrer, en rajoutant la contrainte d'orthogonalité aux directions précédentes, que les solutions à cette dernière équation, les vecteurs propres de la matrice de Covariance, sont bien l'ensemble des vecteurs maximisant la variance projetée, tout en fournissant un repère orthonormé.

On retrouve donc le résultat connu de la théorie de l'ACP, qui est que trouver la direction qui maximise la variance projetée de notre jeu de données revient à déterminer les vecteurs propres de la matrice de Covariance.

Comme $\vec{u}$ est unitaire, on peut également montrer rapidement que

$$C\vec{u} = \lambda\vec{u} \Rightarrow \vec{u}^T C\vec{u} = \vec{u}^T \lambda\vec{u} \Rightarrow \vec{u}^T C\vec{u} = \lambda \times \|\vec{u}\| \Rightarrow \vec{u}^T C\vec{u} = \lambda$$

Autrement dit λ , qui est à la fois le multiplicateur lagrangien de notre problème d'optimisation et la valeur propre du vecteur propre associé, est aussi la variance projetée associée à une composante principale.


Annexe D

Principe du *Tree-Structured Parzen Estimator*


La figure D.1 illustre son fonctionnement dans un cas unidimensionnel simple, où il ne s'agit d'optimiser qu'un hyperparamètre. L'algorithme commence par tester un nombre fixé au préalable de combinaisons d'hyperparamètres aléatoires D.1a. Pour chaque combinaison il calcule une métrique cible, par exemple le f1-score, que l'optimisation cherche à maximiser. Les points échantillonnés sont alors classés en bons et mauvais, selon une proportion également définie à l'appel de l'algorithme.

Pour chacun des deux groupes, on construit un *Parzen Estimator* (fig D.1b), que l'on considère comme la densité de probabilité qu'un point donné face parti du groupe. Cet estimateur est construit en calculant, pour chaque point x_i une fonction normale $\mathcal{N}(x_i, \sigma^2)$ avec $\sigma = \max(x_i - x_{i-1}, x_{i+1} - x, s)$, où s est un écart-type minimal fixé. Autrement dit, l'écart type est la plus grande distance entre un point et ses voisins dans la dimension de l'hyperparamètre, ou un écart-type minimal fixé pour éviter de trop petits écart-types.


On peut alors construire la densité de probabilité d'amélioration du f1-score, comme le ratio du *Parzen Estimator* des bons échantillons sur celui des mauvais D.1c. Le point maximisant cette fonction est celui que l'on considérera comme donnant le maximum de chances d'améliorer le score cible et qui est donc la prochaine combinaison que l'algorithme testera. Ce processus peut-être répété un nombre arbitraire de fois.



(a) Echantillonnage aléatoire



(b) Parzen Estimator comme somme de gaussiennes



(c) Obtention du point d'amélioration attendue maximale par ratio des distributions estimées des bons et mauvais échantillons

FIGURE D.1 – Fonctionnement de l'optimisation par Tree-Structured Parzen Estimator

Annexe E

Théorie de l'Information Mutuelle

L'information mutuelle de deux variables X et Y est une métrique permettant de répondre à la question "à quel point connaître Y me permet d'améliorer ma prédiction de X ?". Sa formalisation mobilise le concept d'entropie, issu de la théorie de l'information. L'information mutuelle de X et Y est ainsi définie comme $I(X, Y) = H(X) - H(X|Y)$, où $H(X)$ est l'entropie de X .

L'entropie est définie par la théorie de l'information comme le taux de compression maximal d'un signal, que pourrait atteindre un compresseur parfait. La méthode de calcul de ce taux peut-être appréhendée avec un exemple. Si un signal contient quatre modalités différentes, A, B, C et D, la méthode par défaut pour encoder chaque modalité en bits utiliserait deux bits par modalité¹. Cependant, si $P(A) = \frac{1}{2}$, $P(B) = \frac{1}{4}$, $P(C) = \frac{1}{8}$ et $P(D) = \frac{1}{8}$, il est possible de montrer et il n'est pas dur de se convaincre, que la méthode la plus compressée pour encoder ce signal est d'utiliser un bit pour A, 2 pour B et 3 pour C et D². Dès lors, le nombre de bits moyen pour encoder une modalité devient :

$$\frac{1}{2} \times 1 + \frac{1}{4} \times 2 + \frac{1}{8} \times 3 + \frac{1}{8} \times 3 = 1.75$$

ce qui est bien inférieur à 2 bits par modalité. On peut ainsi montrer que le nombre de bit optimal n , d'une modalité m de probabilité $p(m)$, correspond à la puissance de $1/2$ qui permet d'obtenir $p(m)$. En d'autre terme, $p(m) = \frac{1}{2^n}$. D'où il découle que $n = -\log_2(p(m))$. Ce nombre optimal de bit n est appelé l'information de m . Et l'entropie est l'information moyenne d'un signal. 1.75 est ainsi l'entropie de notre signal d'exemple. On peut noter que le fait que le log de la formule de l'entropie soit en base 2 est uniquement lié au fait qu'on s'intéresse au nombre de bit optimal moyen et que les bits n'ont que deux modalités. Dans le cas général, la théorie de l'information utilise parfois le log naturel et non le log en base 2. L'entropie d'une variable aléatoire X est donc simplement la généralisation du calcul que nous avons fait pour notre signal d'exemple et peut s'écrire :

$$H(X) = - \sum_k^m P(X = k) \times \log(P(X = k))$$

L'information mutuelle de X et Y étant l'écart de l'entropie de X et de l'entropie de X sachant Y , on comprend que cela mesure à quel point connaître Y permet d'améliorer notre prédiction de X , ce qui correspond bien à la question "à quel point connaître Y me permet d'améliorer ma prédiction de X ?". L'information mutuelle nous donne donc bien une mesure de l'intensité de la dépendance entre deux variables. Une information mutuelle de 0 signifie que les deux variables sont tout à fait indépendantes et plus elle est grande, plus connaître Y permet d'améliorer la compression de X .

1. Par exemple A :00 ; B :01 ; C :10 ; D :11.

2. Les codes exacts non ambigus, seraient alors par exemple A :0 ; B :10 ; C :110 ; D :111.